

## Сборник заметок по СУБД PostgreSQL

### Содержание

<b>1</b>	<b>Замечания по использованию различных баз данных для различных проектов</b>	<b>3</b>
<b>2</b>	<b>Ответвления от PostgreSQL</b>	<b>4</b>
<b>3</b>	<b>Хранилища данных</b>	<b>4</b>
<b>4</b>	<b>Файл подкачки</b>	<b>5</b>
<b>5</b>	<b>Буферный кеш в PostgreSQL</b>	<b>5</b>
<b>6</b>	<b>Сброс пароля для psql и pgAdmin4</b>	<b>6</b>
<b>7</b>	<b>Создание резервной копии базы данных</b>	<b>7</b>
<b>8</b>	<b>Логический порядок обработки инструкции SELECT</b>	<b>7</b>
<b>9</b>	<b>Смена схемы базы данных</b>	<b>8</b>
<b>10</b>	<b>Создание таблицы</b>	<b>8</b>
10.1	Базовые синтаксис создания таблицы . . . . .	8
10.2	Создать таблицу по образу другой таблицы . . . . .	10
<b>11</b>	<b>Подзапросы</b>	<b>10</b>
11.1	Латеральные подзапросы . . . . .	10
11.2	Дополнительные средства группировки . . . . .	12
11.3	Дополнительные виды агрегирования . . . . .	13
<b>12</b>	<b>Копирование данных между файлом и таблицей</b>	<b>15</b>
<b>13</b>	<b>Обновление записей. Команда UPDATE</b>	<b>15</b>
<b>14</b>	<b>Общие табличные выражения</b>	<b>16</b>
14.1	Конструкция WITH . . . . .	16
14.2	Конструкция WITH RECURSIVE . . . . .	18
14.3	Изменение данных в WITH . . . . .	20
<b>15</b>	<b>Оконные функции</b>	<b>21</b>
15.1	Определение окна . . . . .	21
15.2	Фраза WINDOWS . . . . .	22
15.3	Использование оконных функций . . . . .	22

<b>16 Продвинутые методы работы с SQL</b>	<b>26</b>
16.1 Выборка первых записей . . . . .	26
<b>17 Пользовательские типы данных</b>	<b>27</b>
<b>18 Работа со строками и регулярные выражения</b>	<b>29</b>
<b>19 Программирование на PL/pgSQL</b>	<b>31</b>
19.1 Примеры работы с функциями . . . . .	31
19.2 Итерирование . . . . .	33
19.3 Возврат из функции . . . . .	35
19.4 Обработка исключений . . . . .	36
19.5 Динамический SQL . . . . .	37
<b>20 Массивы</b>	<b>39</b>
20.1 Функции и операторы массивов . . . . .	41
20.2 Доступ к элементам массива и их модификация . . . . .	41
20.3 Индексирование массивов . . . . .	43
<b>21 Хранилище ключей и значений</b>	<b>43</b>
21.1 Индексирование hstore . . . . .	45
<b>22 Структура данных JSON</b>	<b>46</b>
22.1 JSON и XML . . . . .	46
22.2 Типы данных JSON в PostgreSQL . . . . .	46
22.3 Доступ к объектам типа JSON и их модификация . . . . .	46
22.4 Индексирование JSON-документов . . . . .	47
<b>23 PostgreSQL и Python</b>	<b>48</b>
23.1 Простой пример работы с PostgreSQL через библиотеки SQLAlchemy и psycopg2 . . . . .	48
<b>24 Приемы работы в pgAdmin 4</b>	<b>50</b>
<b>25 Приемы работы в psql</b>	<b>50</b>
25.1 Конфигурационный файл . . . . .	50
25.2 Метакоманды psql . . . . .	50
25.3 Примеры использования . . . . .	51
<b>26 Специальные функции и операторы</b>	<b>52</b>
26.1 Предикаты ANY, ALL . . . . .	52
26.2 Оператор конкатенации . . . . .	52
26.3 Диапазонные операторы . . . . .	52
26.4 Функции, генерирующие ряды значений . . . . .	53
26.5 Функции для работы с массивами . . . . .	55
26.6 Операторы и функции даты/времени . . . . .	55
26.7 Выполнение динамически формируемых команд . . . . .	56
26.8 Функции и операторы JSON . . . . .	58

<b>27 Наиболее полезные команды PostgreSQL</b>	<b>60</b>
27.1 Команда VACUUM . . . . .	60
<b>Список литературы</b>	<b>60</b>

## 1. Замечания по использованию различных баз данных для различных проектов

Небольшому стартапу лучше выбрать одну из реляционных баз данных, например, MySQL или PostgreSQL – они подходят для широкого круга задач. Быстрорастущим компаниям есть смысл использовать сразу две-три СУБД. Например, MySQL или PostgreSQL для длительного хранения данных, а Redis – для быстрой обработки запросов.

Проще и дешевле масштабировать облачные базы данных – для проектов с непредсказуемой нагрузкой лучше всего подходят PostgreSQL или MongoDB в конфигурации, предназначенной для быстрого выделения ресурсов. В случае резкого роста трафика компания получает дополнительные мощности облачной СУБД автоматически или по запросу. При этом оплачиваются только фактически потраченные ресурсы.

Если информации для анализа очень много и требуется чтобы машинный алгоритм мог сделать выводы на их основе, необходимо быстро извлекать данные по заданным критериям. С этой задачей не справятся реляционные базы данных MySQL и PostgreSQL – они долго обрабатывают большие массивы информации. Здесь нужна специальная аналитическая база данных, например, ClickHouse. Она быстро выполняет аналитические запросы.

Некоторые сервисы должны быстро обрабатывать запросы пользователей, в том числе в режиме реального времени – для проведения транзакций, аналитики в реальном времени, счетчиков, аутентификации и других операциях, предполагающих быстрый ответ базы данных. Для таких ситуаций подойдет Redis – нереляционная высокопроизводительная СУБД. Redis хранит данные в оперативной памяти, за счет этого отвечает на запросы в десятки раз быстрее, чем MySQL или PostgreSQL. Redis можно использовать и как самостоятельную СУБД, и как дополнительную СУБД в тех случаях, когда число запросов резко растет и нужно быстро их обработать.

Иногда бизнесу требуется решать узко специализированные задачи. Например, шифровать пароли, составлять рейтинги, анализировать маршруты транспорта или следить за передвижением курьеров в реальном времени. Нужна база данных, позволяющая подключать расширения или использовать команды для решения нестандартных задач.

Для PostgreSQL и Postgres Pro разработано большое количество дополнительных расширений. Например, расширение для криптографии шифрует личные данные для безопасной передачи по сети. В случае кражи злоумышленники получают только обезличенную информацию. А расширение PostGIS подходит для картографических сервисов, например, для поиска по географическим данным.

В Redis есть наборы специальных команд и операторов, позволяющих использовать базу данных для решения узких задач в режиме реального времени. Например, составления рейтингов игроков в играх, аналитики контента, управления геоданными, в том числе отслеживания местоположения транспорта.

Итак:

- У стартапа может смениться бизнес-модель. Поэтому лучше выбрать СУБД, подходящую для решения широкого круга задач, или заложить сразу две-три базы данных,
- В бизнесе, где нагрузка на инфраструктуру зависит от сезона, важно быстро масштабировать базу данных – это удобно делать в облаке,
- Хранить информацию в неизменном виде позволяют реляционные базы данных, например, MySQL или PostgreSQL,
- Для работы с большими данными подойдет ClickHouse – база данных, позволяющая быстро выполнять аналитические запросы,
- Быстро отвечать на запросы пользователей позволяет Redis – нереляционная высокопроизводительная СУБД, она хранит данные в оперативной памяти.

## 2. Ответвления от PostgreSQL

От PostgreSQL существует более 20 ответвлений. На протяжении многих лет различные группы создавали ответвления и затем включали результаты своей работы в PostgreSQL:

- HadoopDB – гибрид PostgreSQL с технологиями MapReduce, ориентированный на аналитику,
- Greenplum – реляционная СУБД, имеющая массово-параллельную архитектуру без разделения ресурсов. Или еще можно сказать, что Greenplum представляет собой кластер над экземплярами PostgreSQL без разделения ресурсов с массово параллельной обработкой (MPP). Применяется для создания хранилищ данных и аналитики,
- Vertica – столбцовая СУБД ориентированная на аналитику данных. Терминальный клиент для Python можно изучить на странице проекта <https://github.com/vertica/vertica-python>,
- Amazon Redshift – популярное хранилище данных на базе PostgreSQL 8.0.2. Предназначено в основном для OLAP-приложений.

## 3. Хранилища данных

Хранилище данных (Data Warehouse) – предметно-ориентированная информационная база данных, специально разработанная и предназначенная для подготовки отчетов и бизнес-анализа с целью поддержки принятия решений в организации. Строится на базе систем управления базами данных и систем поддержки принятия решений. Данные, поступающие в хранилища, как правило, доступны только для чтения.

Существует два варианта *обновления* данных в хранилище:

- *полное* обновление данных в хранилище. Сначала старые данные удаляются, потом происходит загрузка новых данных. Процесс выполняется с определенной периодичностью, при этом актуальность данных может несколько отставать от OLTP-системы,
- *инкрементальное* обновление – обновляются только те данные, которые изменились в OLTP-системе.

Принципы организации хранилища:

- *Проблемно-предметная ориентация*: данные объединяются в категории и хранятся в соответствии с областями, которые они описывают, а не с приложениями, которые они используют,

- *Интегрированность*: данные объединены так, чтобы они удовлетворяли всем требованиям предприятия в целом, а не единственной функции бизнеса,
- *Некорректируемость*: данные в хранилище не создаются; то есть данные поступают из внешних источников, не корректируются и не удаляются,
- *Зависимость от времени*: данные в хранилище точны и корректны только в том случае, когда они привязаны к некоторому промежутку или моменту времени.

Существует два архитектурных направления:

- нормализованные хранилища данных,
- хранилища данных с измерениями.

В нормализованных хранилищах, данные находятся в предметно-ориентированных таблицах третьей нормальной формы. Нормализованные хранилища характеризуются как простые в создании и управлении, недостатки нормализованных таблиц – большое количество таблиц как атрибут нормализации, в следствие чего для получения какой-либо информации нужно делать выборку из многих таблиц одновременно, что приводит к снижению производительности системы. Для решения этой проблемы используются денормализованные таблицы – витрины данных, на основе которых уже выводятся отчетные формы. При очень больших объемах данных могут использоваться несколько уровней витрин/хранилищ.

Хранилища с измерениями используют схему «звезда» или «снежинка». При этом в центре «звезды» находятся данные (таблица фактов), а измерения образуют лучи звезды. Различные таблицы фактов совместно используют таблицы измерений, что значительно облегчает операции объединения данных из нескольких предметных таблиц фактов. Основным недостатком является более сложные процедуры подготовки и загрузки данных, а также управление и изменение измерений данных.

## 4. Файл подкачки

Подкачка страниц представляет собой механизм виртуальной памяти, перемещающий неиспользуемые (неактивные) фрагменты памяти в другое хранилище (жесткий диск или какое-либо другое место), тем самым освобождая место в оперативной памяти для загрузки активных данных. В качестве хранилища могут выступать раздел подкачки или файл подкачки (swap-файл). Раздел подкачки обычно создается в момент установки операционной системы, а файл подкачки можно создать в любой момент, главное чтобы было место.

Пространство подкачки главным образом используется для расширения виртуальной памяти за пределы установленной оперативной памяти (RAM).

Ресурс твердотельных накопителей (SSD) напрямую зависит от числа циклов записи/перезаписи, поэтому не рекомендуется использовать swap на SSD.

## 5. Буферный кеш в PostgreSQL

Размер кеша устанавливается параметром `shared_buffers`. Значение по умолчанию смехотворное – 128 Мб. Это один из параметров, которые имеет смысл увеличить сразу же после установки PostgreSQL.

```
SELECT setting, unit
FROM pg_settings
WHERE name = 'shared_buffers';
```

```
+-----+-----+
| setting | unit |
+-----+-----+
| 16384   | 8kB  |
+-----+-----+
```

Надо иметь в виду, что изменение параметра требует перезапуска сервера, поскольку вся необходимая под кеш память выделяется при старте сервера.

Оптимальное значение буферного кеша зависит данных, приложения, нагрузки и т.п. Стандартная рекомендация – взять в качестве первого приближения 1/4 оперативной памяти, а дальше по ситуации.

Исключение из общего правила представляют временные таблицы. Поскольку временные данные видны только одному процессу, им нечего делать в общем буферном кеше. Более того, временные данные существуют только в рамках одного сеанса, так что их не нужно защищать от сбоя.

Для временных данных используется кеш в локальной памяти того процесса, который владеет таблицей. Поскольку такие данные доступны только одному процессу, их не требуется защищать блокировками. В локальном кеше используется обычный алгоритм вытеснения.

В отличие от общего буферного кеша, память под локальный кеш выделяется по мере необходимости, ведь временные таблицы используются далеко не во всех сеансах. Максимальный объем памяти для временных таблиц одного сеанса ограничен параметром `temp_buffers`.

Для справки перезапустить сервер на Windows, используя командную оболочку `bash`, можно с помощью утилиты `pg_ctl` так

```
pg_ctl restart -D '/c/Program Files/PostgreSQL/11/data'
```

или так, если использовать `cmd.exe`

```
pg_ctl start -D "C:\Program Files\PostgreSQL\11\data"
```

А посмотреть статус можно так

```
pg_ctl status -D "C:\Program Files\PostgreSQL\11\data"
```

## 6. Сброс пароля для psql и pgAdmin4

Для того чтобы доступ к базам данных через терминальный клиент `psql` или через web-интерфейс `pgAdmin4` можно было выполнять без ввода пароля, нужно сделать следующее:

- найти файл `pg_hba.conf`; на ОС Windows он располагается по адресу `C:\Program Files\PostgreSQL\11\data`,
- заменить в этом файле метод `md5` (в нижней части файла) на `trust`.

После исправлений файл `pg_hba.conf` должен выглядеть приблизительно так

pg\_hba.conf

```
...
# TYPE  DATABASE        USER            ADDRESS                 METHOD
# IPv4 local connections:
host    all             all             127.0.0.1/32           trust
host    all             all             0.0.0.0/0              trust
```

```
# IPv6 local connections:
host    all             all             ::1/128         trust
host    all             all             ::0/0           trust
# Allow replication connections from localhost, by a user with the
# replication privilege.
host    replication     all             127.0.0.1/32    trust
host    replication     all             ::1/128         trust
host    appdb           app            all             trust
```

## 7. Создание резервной копии базы данных

Задачу резервного копирования можно запускать с выделенного backup-сервера или с сервера базы данных. В комплекте PostgreSQL есть 2 утилиты, которые позволяют делать резервные копии: `pg_dump`, `pg_dumpall` (сохраняют резервную копию базы данных в текстовом файле или другом виде) и `pg_basebackup` (делает базовую резервную копию *работающего* сервера PostgreSQL). Кроме того есть возможность использовать утилиты файлового копирования, такие `rsync`, `tar`, `cp` и т.п.

Утилита `pg_dump` подходит для случаев, когда нужно сделать резервную копию таблицы, базы или схемы, а `pg_basebackup` – подходит для случаев, когда нужно сделать резервную копию целиком всего кластера базы данных или настроить реплику. Утилиты `rsync`, `tar`, `cp` также используются для случаев копирования всего кластера.

Примеры создания резервной копии базы данных

```
pg_dump -U postgres -d demo --format=tar -v -f $(date +%Y-%m-%d).demo.tar
pg_dump -U postgres -d demo -f $(date +%Y-%m-%d).demo.sql
```

Создать резервную копию с backup-сервера в каталог `/backup` (каталог должен существовать)

```
pg_basebackup -x -h db01.example.com -U backup -D /backup
```

Копирование со сжатием в `bzip2`, для случаев, когда нужно использовать нестандартный алгоритм сжатия

```
pg_basebackup -x --format=tar -h db01.example.com -U backup -D - | bzip2 -9 > /backup/db01/
backup-$(date +%Y-%m-%d).tar.bz2
```

Копирование со сжатием в несколько потоков (задействуем 8 ядер)

```
pg_basebackup -x --format=tar -h db01.example.com -U backup -D - | lbzip2 -n 8 -9 > /backup/db01/
backup-$(date +%Y-%m-%d).tar.bz2
```

Копирование запускается на сервере базы данных. Формируемая резервная копия отправляется на удаленный сервер по `ssh`

```
pg_basebackup -x --format=tar -h 127.0.0.1 -U backup -D - | \
ssh backup@backup.example.com "tar -xf - -C /backup/"
```

Восстановить данные из созданных backup-файлов можно с помощью утилиты `pg_restore`.

## 8. Логический порядок обработки инструкции SELECT

Порядок обработки инструкции `SELECT` определяет, когда объекты, определенные в одном шаге, становятся доступными для предложений в последующих шагах. Например, если обработчик

запросов можно привязать к таблицам или представлениям, определенным в предложении **FROM**, эти объекты и их столбцы становятся доступными для всех последующих шагов.

Общая процедура выполнения **SELECT** следующая (подробности см. в документации [SELECT](#)):

1. **WITH**: выполняются все запросы в списке **WITH**; по сути они формируют временные таблицы, к которым затем можно обращаться в списке **FROM**; запрос в **WITH** выполняется только один раз, даже если он фигурирует в списке **FROM** неоднократно,
2. **FROM**: вычисляются все элементы в списке **FROM** (каждый элемент в списке **FROM** представляет собой реальную или виртуальную таблицу); другими словами конструируются таблицы из списка **FROM**,
3. **ON**: выбираются строки, удовлетворяющие заданному условию,
4. **JOIN**: выполняется объединение таблиц,
5. **WHERE**: исключаются строки, не удовлетворяющие заданному условию,
6. **GROUP BY**: вывод разделяется по группам строк, соответствующим одному или нескольким значениям, а затем вычисляются результаты агрегатных функций,
7. **HAVING**: исключаются группы, не удовлетворяющие заданному условию,
8. **SELECT**,
9. **DISTINCT**: исключаются *повторяющиеся* строки; **SELECT DISTINCT ON** исключает строки, совпадающие по всем указанным выражениям; **SELECT ALL** (по умолчанию) возвращает все строки результата, включая дубликаты,
10. **UNION**, **INTERSECT** и **EXCEPT**: объединяется вывод нескольких команд **SELECT** в один результирующий набор.
11. **ORDER BY**: строки сортируются в указанном порядке; в отсутствие **ORDER BY** строки возвращаются в том порядке, в каком системе будет проще их выдавать,
12. **LIMIT** (или **FETCH FIRST**), либо **OFFSET**: возвращается только подмножество строк результата.
13. Если указано **FOR UPDATE**, **FOR NO KEY UPDATE**, **FOR SHARE** или **FOR KEY SHARE**, оператор **SELECT** блокирует выбранные строки, защищая их от одновременных изменений.

## 9. Смена схемы базы данных

Вывести список доступных схем

```
SHOW search_path;
```

Задать схему

```
SET search_path TO new_schema;
```

или, если требуется доступ к нескольким схемам

```
SET search_path TO new_schema1, new_schema2, public;
```

## 10. Создание таблицы

### 10.1. Базовые синтаксис создания таблицы

Для создания таблиц в языке SQL служит команда **CREATE TABLE**. Упрощенный синтаксис таков



```
CREATE TABLE table_name(
    field_name data_type [constraint],
    field_name data_type [constraint],
    ...
    [constraint],
    [primary key],
    [foreign key]
);
```

Пример

```
CREATE TABLE aircrafts(
    aircraft_code CHAR(3) NOT NULL,
    model TEXT NOT NULL,
    range INTEGER NOT NULL,
    CHECK (range > 0),           -- ограничение
    PRIMARY KEY (aircraft_code) -- первичный ключ
);
```

Создать таблицу с автоматическим вычислением идентификационного номера строки

```
CREATE TABLE test(
    id SERIAL PRIMARY KEY,
    name TEXT
);
```

Теперь при вставке строки без явного указания идентификационного номера последний будет вычисляться автоматически<sup>1</sup>

```
INSERT INTO test(name) VALUES ('Ansys') RETURNING id;
```

Выведет

```
+----+
| id |
+----+
|  1 |
+----+
```

Еще возвращенное значение можно было бы прочитать с помощью *анонимной функции*

```
DO $$ -- анонимная функция
DECLARE -- объявление переменной
    auto_generated_id INT;
BEGIN
    -- значение атрибута id, которое возвращает RETURNING
    -- можно связать с переменной auto_generated_id с помощью ключевого слова INTO
    INSERT INTO test(name) VALUES ('Nastran') RETURNING id INTO auto_generated_id;
    RAISE NOTICE 'The primary key is: %', auto_generated_id;
END
$$;
```

Выведет

```
NOTICE: The primary key is: 2
```

<sup>1</sup>Если при вставке строки имена некоторых атрибутов явно не указываются, то считается, что значения этих атрибутов вычисляются автоматически, в противном случае они имеют значение <NULL>

## 10.2. Создать таблицу по образцу другой таблицы

Создать таблицу со структурой данных, аналогичной другой таблице (но *без* ограничений базовой таблицы) можно так

```
CREATE TABLE tbl_name AS
  SELECT * FROM base_tbl LIMIT 0;
```

или более короткий вариант

```
CREATE TABLE tbl_name(LIKE base_tbl);
```

## 11. Подзапросы

По связанности подзапросы делятся на:

- *связанные* (или коррелированные) подзапросы, т.е. такие подзапросы, которые ссылаются на элементы внешнего подзапроса или элементы главного запроса,
- *несвязанные* (или некоррелированные) подзапросы.

Фундаментальная концепция состоит в том, что связанные подзапросы выполняются для *каждой* записи (строки) из внешнего подзапроса (или главного запроса), а несвязанные выполняются только один раз.

### 11.1. Латеральные подзапросы

Очень удобно использовать подзапросы в списке выборке. Например, в командах **SELECT** с их помощью можно создавать вычисляемые атрибуты при опросе таблицы. Пример с использованием скалярных подзапросов

```
SELECT
  car_id,
  manufacture_year,
  CASE WHEN manufacture_year <= (
    SELECT avg(manufacture_year) FROM car_portal_app.car
    WHERE car_model_id = c.car_model_id
  ) THEN 'old' ELSE 'new'
  END AS age,
  (SELECT count(*) FROM car_portal_app.car
   WHERE car_model_id = c.car_model_id) AS same_model_count
FROM car_portal_app.car AS c;
```

Эти подзапросы интересны тем, что могут ссылаться на главную таблицу в своей фразе **WHERE**. С помощью подобных подзапросов легко добавить в запрос дополнительные столбцы. Но есть проблема – производительность. Таблица **car** просматривается сервером один раз в главном запросе, а затем еще два раза для каждой выбранной строки, т.е. для столбцов **age** и **same\_model\_count**. Другими словами, выбирается значение атрибута **car\_model\_id** таблицы **car** подзапроса для каждой строки таблицы **car** главного запроса. Для каждой строки главного запроса вычисляется скалярный подзапрос, связанный с псевдонимом **age**, и возвращающий для каждой строки год производства автомобиля, усредненный по группе марок автомобиля. А затем аналогичная процедура повторяется для второго подзапроса, связанного с псевдонимом **same\_model\_count**.

Конечно, можно независимо вычислить эти агрегаты по одному разу для каждой модели, а затем соединить результаты с таблицей **car**

```

SELECT
    car_id,
    manufacture_year,
    CASE
        WHEN manufacture_year <= avg_year THEN 'old'
        ELSE 'new'
    END AS age,
    same_model_count
FROM car_portal_app.car
    INNER JOIN (
        SELECT
            car_model_id,
            avg(manufacture_year) AS avg_year,
            count(*) AS same_model_count
        FROM car_portal_app.car
        GROUP BY car_model_id
    ) AS subq
    USING (car_model_id);

```

Результат тот же самый, а запрос выполняется значительно быстрее. Однако этот запрос хорош только тогда, когда нужно выбрать из базы данных много строк. Если нужно получить информацию только об одном автомобиле, то первый запрос будет быстрее.

Существует еще один способ использования подзапросов. Он сочетает в себе преимущества подзапросов в списке выборки, способных обращаться к главной таблице из фразы **WHERE**, с подзапросами во фразе **FROM**, которые могут возвращать несколько столбцов. Если поместить ключевое слово **LATERAL** перед подзапросом во фразе **FROM**, то он сможет ссылаться на любой элемент, предшествующий ему во фразе **FROM**.

Запрос выглядит следующим образом

```

SELECT
    car_id,
    manufacture_year,
    CASE
        WHEN manufacture_year <= avg_year THEN 'old'
        ELSE 'new'
    END AS age,
    same_model_count
FROM
    car_portal_app.car AS c,
    LATERAL ( -- латеральный связанный подзапрос; выполняется для каждой строки
               -- таблицы 'car' внешнего запроса
        SELECT
            avg(manufacture_year) AS avg_year,
            count(*) AS same_model_count
        FROM car_portal_app.car
        WHERE car_model_id = c.car_model_id
    ) AS subq; -- у подзапроса во фразе FROM обязательно должен быть псевдоним

```

Итак, ключевое слово **LATERAL** позволяет ссылаться в подзапросах на столбцы предшествующих элементов списка **FROM**. Без **LATERAL** каждый подзапрос выполняется независимо и поэтому не может обращаться к другим элементам **FROM**.

---

#### Замечание

В контексте фразы **FROM** по умолчанию подзапросы не могут ссылаться на другие элементы фразы **FROM**.

---

Когда элемент **FROM** содержит ссылки **LATERAL**, запрос выполняется следующим образом: сначала для строки элемента **FROM** с целевыми столбцами, или набора строк из нескольких элементов **FROM**, содержащих целевые столбцы, вычисляется элемент **LATERAL** со значением этих столбцов. Затем результирующие строки обычным образом соединяются со строками, из которых они были вычислены. Эта процедура повторяется для всех строк исходных таблиц.

Применять **LATERAL** имеет смысл в основном, когда для вычисления соединяемых строк необходимо обратиться к столбцам других таблиц.

Особенно полезно бывает использовать **LEFT JOIN** с подзапросом **LATERAL**, чтобы исходные строки оказались в результате, даже если подзапрос **LATERAL** не возвращает строк. Например, если функция `get_product_names()` выдает названия продуктов, выпущенных определенным производителем, но о продукции некоторых производителей информации нет, мы можем найти, каких именно, примерно так:

```
SELECT m.name
FROM manufacturers m LEFT JOIN LATERAL get_product_names(m.id) pname ON true
WHERE pname IS NULL;
```

Рассмотренный запрос работает приблизительно в два раза быстрее первого, он оптимален, когда нужно выбрать из таблицы `car` всего одну строку.

Синтаксис **JOIN** также допускается в латеральных подзапросах, хотя в большинстве случаев условие соединения каким-то образом включается во фразу **WHERE** подзапросов.

Употреблять **LATERAL** с функциями, возвращающими множества, нет необходимости. Все функции, упомянутые во фразе **FROM**, и так могут использовать результаты любых предшествующих функций или подзапросов.

## 11.2. Дополнительные средства группировки

Базы данных часто служат источником данных для различных отчетов. А в отчетах принято в одной и той же таблице показывать подытоги, итоги и общие итоги, подразумевающие группировку и агрегирование. Рассмотрим отчет о количестве объявлений в разрезе марок и кварталов, в котором требуется также показать итоги по каждому кварталу (суммарно по всем маркам) и общий итог. Вот как отбираются данные для такого отчета

```
SELECT
    to_char(advertisement_date, 'YYYY-Q') AS quarter,
    make,
    count(*)
FROM advertisement a
    INNER JOIN car c ON a.car_id = c.car_id
    INNER JOIN car_model m ON m.car_model_id = c.car_model_id
GROUP BY quarter, make;
```

Выведет

quarter	make	count
2014-4	Peugeot	12
2014-2	Daewoo	8
2014-4	Skoda	5
...		

Чтобы вычислить итоги, понадобятся дополнительные запросы

```

SELECT to_char(advertisement_date, 'YYYY-Q') AS quarter, count(*)
FROM advertisement a
     INNER JOIN car c ON a.car_id = c.car_id
     INNER JOIN car_model m ON m.car_model_id = c.car_model_id
GROUP BY quarter;

SELECT count(*)
FROM advertisement a
     INNER JOIN car c ON a.car_id = c.car_id
     INNER JOIN car_model m ON m.car_model_id = c.car_model_id;

```

PostgreSQL позволяет объединить все три запроса в один с помощью специальной конструкции GROUP BY GROUPING SETS

```

SELECT
    to_char(advertisement_date, 'YYYY-Q') AS quarter,
    make,
    count(*)
FROM advertisement a
     INNER JOIN car c ON a.car_id = c.car_id
     INNER JOIN car_model m ON m.car_model_id = c.car_model_id
GROUP BY GROUPING SETS ((quarter, make), (quarter), ()) -- << NB
ORDER BY quarter NULLS LAST, make NULLS LAST;

```

Благодаря конструкции GROUPING SETS ((quarter, make), (quarter), ()) запрос работает как UNION ALL одинаковых запросов с разными фразами GROUP BY:

- GROUP BY quarter, make,
- GROUP BY – здесь поле make будет иметь значение NULL,
- все строки помещаются в одну группу, оба поля – quarter и make – будут иметь значение NULL.

Вообще говоря, фраза GROUP BY принимает не только выражения, но и группирующие элементы, которые могут быть выражениями или конструкциями типа GROUPING SETS.

Два других группирующих элемента – ROLLUP и CUBE

- ROLLUP (a, b, c) эквивалентно GROUPING SETS ((a, b, c), (a, b), (c), ()).
- CUBE (a, b, c) эквивалентно GROUPING SETS ((a, b, c), (a, b), (a, c), (b, c), (a), (b), (c), ()) – все возможные комбинации аргументов.

Разрешено также комбинировать различные группирующие элементы в одной фразе GROUP BY, например: GROUP BY a, CUBE (b, c) – по сути дела, комбинация группирующих элементов.

### 11.3. Дополнительные виды агрегирования

Есть несколько агрегатных функций, которые выполняются специальным образом. Первая группа таких функций называется *агрегатами по упорядоченному множеству*. Они учитывают не только значения выражений, переданных в качестве аргументов, но и их порядок.

PostgreSQL позволяет вычислить непрерывный или дискретный процентиль с помощью функций percentile\_cont и percentile\_disc соответственно.

Дискретный процентиль совпадает с одним из значений группы, а непрерывный – результат интерполяции двух существующих значений. Есть возможность вычислить один процентиль для заданной процентной доли или сразу несколько процентилей для заданного массива долей.

Вот, например, запрос о распределении количества объявлений по автомобилям

```
SELECT percentile_disc('{0.25, 0.5, 0.75}'::real[]) WITHIN GROUP (ORDER BY range)
FROM aircrafts;
```

ВЫВЕДЕТ

```
+-----+
| percentile_disc |
+-----+
| {3000,5600,6700} |
+-----+
```

Результат означает, что для 25 процентов наблюдений *не превосходят* 3000, 50 процентов – 5600, а 75 процентов – 6700.

Синтаксис агрегатных функций по упорядоченному множеству отличается от обычных агрегатных функций, в нем используется специальная конструкция `WITHIN GROUP (ORDER BY expression)`. Здесь выражение **expression** – фактически аргумент функции. На результат функции влияет не только порядок строк, но и значения этих выражений. В противоположность фразе `GROUP BY` в команде `SELECT` допускается только одно выражение, и ссылок на номера результирующих столбцов быть не должно.

Еще один достойный упоминания аспект агрегатных функций – фраза `FILTER`. Она по заданному условию отфильтровывает строки, передаваемые агрегатной функции. Например, пусть требуется подсчитать количество автомобилей для каждой модели и каждого значения количества дверей

```
SELECT
    car_model_id,
    count(*) FILTER (WHERE number_of_doors = 2) doors2,
    count(*) FILTER (WHERE number_of_doors = 3) doors3,
    count(*) FILTER (WHERE number_of_doors = 4) doors4,
    count(*) FILTER (WHERE number_of_doors = 5) doors5
FROM car_portal_app.car
GROUP BY car_model_id;
```

ВЫВЕДЕТ

```
car_model_id | doors2 | doors3 | doors4 | doors5
-----+-----+-----+-----+-----
          43 |      0 |      0 |      0 |      2
           8 |      0 |      0 |      1 |      0
          11 |      0 |      2 |      1 |      0
          80 |      0 |      1 |      0 |      0
          ...
```

Того же результата можно достичь и таким образом

```
count(CASE WHEN number_of_doors = 2 THEN 1 END) doors2
```

но вариант с фразой `FILTER` короче и проще.

Еще один пример на использование фразы `FILTER`

```
SELECT
    sum(amount) FILTER (WHERE fare_conditions = 'Business') AS business,
    sum(amount) FILTER (WHERE fare_conditions = 'Comfort') AS comfort,
    sum(amount) FILTER (WHERE fare_conditions = 'Economy') AS economy,
FROM ticket_flights;
```

## 12. Копирование данных между файлом и таблицей

Скопировать данные из внешнего файла в таблицу (по сути загрузить данные) можно с помощью команды COPY. С помощью этой же команды можно записать данные из таблицы в файл.

Общий синтаксис команды выглядит так

```
-- копирует содержимое файла в таблицу
COPY имя_таблицы [ ( имя_столбца [, ...] ) ]
  FROM { 'имя_файла' | PROGRAM 'команда' | STDIN }
  [ [ WITH ] ( параметр [, ...] ) ]

-- копирует содержимое таблицы в файл
COPY { имя_таблицы [ ( имя_столбца [, ...] ) ] | ( запрос ) }
  TO { 'имя_файла' | PROGRAM 'команда' | STDOUT }
  [ [ WITH ] ( параметр [, ...] ) ]
```

Здесь допускается параметр:

```
FORMAT имя_формата
OIDS [ boolean ]
FREEZE [ boolean ]
DELIMITER 'символ_разделитель'
NULL 'маркер_NULL'
HEADER [ boolean ]
QUOTE 'символ_кавычек'
ESCAPE 'символ_экранирования'
FORCE_QUOTE { ( имя_столбца [, ...] ) | * }
FORCE_NOT_NULL ( имя_столбца [, ...] )
FORCE_NULL ( имя_столбца [, ...] )
ENCODING 'имя_кодировки'
```

Примеры

```
-- сохранить данные из таблицы 'family' в файл 'family.csv'
postgres=# COPY family TO 'E:/[WorkDirectory]/GARBAGE/family.csv' DELIMITER ',';

-- загрузить в таблицу 'family' данные из файла 'family.csv'
postgres=# CREATE TABLE family (
    person TEXT PRIMARY KEY,
    parent TEXT REFERENCES family -- создать внешний ключ на person
);
postgres=# COPY family FROM 'E:/[WorkDirectory]/GARBAGE/family.csv' DELIMITER ',';
```

## 13. Обновление записей. Команда UPDATE

Изменить слово Drama на Dramatic в столбце kind таблицы films

```
UPDATE films SET kind = 'Dramatic' WHERE kind = 'Drama';
```

Изменить значение температуры и сбросить уровень осадков к значению по умолчанию в одной строке таблицы weather

```
UPDATE
  weather
SET
  temp_lo = temp_lo + 1,
  temp_hi = temp_lo + 15,
  prcp = DEFAULT
```

```
WHERE
```

```
city = 'San Francisco' AND  
dates = '2003-07-03';
```

## 14. Общие табличные выражения

В конструкциях общих табличных выражений с WITH имена временных таблиц указываются без перечисления имен столбцов, а в конструкциях с WITH RECURSIVE – с перечислением, например, `WITH RECURSIVE tab(col1, col2, ...) AS (...)`.

Ссылки на общие табличные выражения в главном запросе можно трактовать как имена таблиц. PostgreSQL выполняет общее табличное выражение *только один раз*, кеширует результаты, а затем повторно использует, вместо того чтобы выполнять подзапросы всякий раз, как они встречаются в главном запросе [1, стр. 169].

### 14.1. Конструкция WITH

Основное предназначение SELECT в предложении WITH (Common Table Expression, Общие Табличные Выражения) заключается в разбиении сложных запросов на простые части. Например, пусть задана некоторая таблица `orders`<sup>2</sup>

```
WITH --part 1, common table expression  
    regional_sales AS ( --def temp_table1  
        SELECT region, sum(amount) AS total_sales  
        FROM orders --base table  
        GROUP BY region  
    ),  
    top_regions AS ( --def temp_table2  
        SELECT region  
        FROM regional_sales --temp_table1  
        WHERE total_sales > (  
            SELECT SUM(total_sales)/10  
            FROM regional_sales --temp_table2  
        )  
    )  
SELECT --part 2  
    region,  
    product,  
    SUM(quantity) AS product_units,  
    SUM(amount) AS product_sales  
FROM orders  
WHERE region IN (  
    SELECT region  
    FROM top_regions --temp_table2  
)  
GROUP BY region, product;
```

Здесь в инструкции WITH объявляются две *временные таблицы* `regional_sales` и `top_regions`. Вторая временная таблица `top_regions` ссылается на временную таблицу `regional_sales`, сформированную в первых строках настоящего запроса. Во второй части запроса также используется временная таблица `top_regions`.

Еще один пример. Пусть задана таблица

---

<sup>2</sup>См. документацию PostgreSQL <https://postgrespro.ru/docs/postgrespro/9.5/queries-with>



```
# SELECT * FROM test_tab;
```

id	cae_name	solver	num_cores
1	ANSYS	Direct	32
3	Comsole	Direct	16
4	LMS Virtual Lab	Direct	32
2	Nastran	Iterativ	16

(4 строки)

Требуется выяснить сколько САЕ-пакетов имеют прямой, а сколько итерационный решатель. Эту задачу можно решить следующим образом

```
WITH sub_tab AS ( --make temp table
    SELECT solver, 1 AS count
    FROM test_tab
)
SELECT solver, sum(count)
FROM sub_tab --link to temp table
GROUP BY solver;
```

Часть с WITH возвращает

```
# SELECT solver, 1 AS count FROM test_tab;
```

solver	count
Direct	1
Direct	1
Direct	1
Iterativ	1

(4 строки)

Полезный пример с использованием конструкции CASE...END и WHEN...THEN

```
WITH cte_film AS ( --part 1
    SELECT
        film_id,
        title,
        (CASE --start block
            WHEN length < 30 THEN 'Short'
            WHEN length < 90 THEN 'Medium'
            ELSE 'Long'
        END) length
    FROM
        film
)
SELECT --part 2
    film_id,
    title,
    length
FROM
    cte_film
WHERE
    length = 'Long'
ORDER BY
    title;
```

Пример с использованием логических операторов

```
WITH cte_films AS (
    SELECT
        film_id,
```

```

        title,
        (CASE
            WHEN length < 30 THEN 'Short'
            WHEN length >= 30 AND length < 90 THEN 'Medium'
            WHEN length > 90 THEN 'Long'
        END) length
    FROM
        film
)

```

## 14.2. Конструкция WITH RECURSIVE

Если к WITH добавить RECURSIVE, то можно будет получить доступ к промежуточному результату. Например,

```

WITH RECURSIVE tbl(n) AS ( --part 1
    SELECT 1 --or VALUES(1). This is nonrecursive part
    UNION ALL
    SELECT n+1 FROM tbl WHERE n < 10 --and this is recursive part
)
SELECT sum(n) from tbl; --part 2

```

На первой итерации в таблице `tbl` в атрибуте `n` находится значение 1. На этом вычисления некурсивной части заканчиваются. Далее переходим к вычислениям в рекурсивной части. Таблица `tbl` ссылается на последнее вычисленное значение, поэтому на второй итерации удастся выполнить `n+1`, после чего новым значением таблицы `tbl` станет 2 (`tbl -> 2`). Проверяем условие `n < 10`, а затем переходим к следующей итерации и т.д.

Удобно представлять, что вычисленные значения хранятся в некоторой промежуточной области в порядке вычисления, а таблица `tbl` всегда ссылается на последнее вычисленное значение.

На последнем этапе 1 объединяется с 2, 3 и т.д., т.е. в итоге получается последовательность от 1 до 10. Во второй части запроса остается лишь просуммировать элементы этой последовательности и вывести на экран.

Рассмотрим еще такой пример

```

WITH RECURSIVE
    included_parts(sub_part, part, quantity) AS (
        SELECT --nonrecursive part
            sub_part,
            part,
            quantity
        FROM parts --base table
        WHERE part = "our_product"
        UNION ALL
        SELECT --recursive part
            p.sub_part,
            p.part,
            p.quantity
        FROM
            included_parts pr,
            parts p
        WHERE p.part = pr.sub_part
    )
SELECT sub_part, SUM(quantity) AS total_quantity
FROM included_parts
GROUP BY sub_part

```

На первой итерации временная таблица `included_parts`, вычисленная в некурсивной части, представляет собой результат выборки строк и столбцов из таблицы `parts`. В рекурсивной части можно получить доступ к этой таблице. В завершении выполняем выборку из таблицы `included_parts` по столбцу `sub_part`, группируем по нему и выводим сумму по `quantity`.

Еще один полезный пример. Пусть дана таблица сотрудников

employees				
id	name	salary	job	manager_id
=====				
1	John	10000	CEO	null
2	Ben	1400	Junior Developer	5
3	Barry	500	Intern	5
4	George	1800	Developer	5
5	James	3000	Manager	7
6	Steven	2400	DevOps Engineer	7
7	Alice	4200	VP	1
8	Jerry	3500	Manager	1
9	Adam	2000	Data Analyst	8
10	Grace	2500	Developer	8
11	Leor	5000	Data Scientist	6

Выведем иерархию подчинения сотрудников в компании

```
WITH RECURSIVE managers(id, name, manager_id, job, level) AS (
  SELECT id, name, manager_id, job, 1
  FROM employees --base table
  WHERE id = 7
  UNION ALL
  SELECT e.id, e.name, e.manager_id, e.job, m.level+1
  FROM employees e JOIN managers m ON e.manager_id = m.id
)
SELECT * FROM managers;
```

Сначала в *некурсивной* части `WITH RECURSIVE` объявляется временная таблица `managers(id, name, ...)`. Она строится на базе таблицы `employees`, к которой слева добавляется столбец, состоящий из одних единиц. Затем выбираются строки, удовлетворяющие условию `WHERE`; в данном случае это одна строка `e.manager_id=m.id`.

И, таким образом, на данном этапе во *временную* таблицу `managers` попадет только одна строка

managers, вычисленная в некурсивной части				
id	name	manager_id	job	level
=====				
7	Alice	1	VP	1

Переходим в рекурсивную часть СТЕ. Из базовой таблицы `employees` выбираем те строки, которые в столбце `manager_id` имеют те же значения, что и в столбце `id` временной таблицы `managers` (на данном этапе таблица состоит из одной строки). Другими словами, выбрать нужно те строки, у которых в столбце `manager_id` таблицы `employees` стоит цифра 7.

В результате временная таблица `managers` на текущем этапе будет иметь вид

managers, вычисленная в рекурсивной части				
id	name	manager_id	job	level
=====				

5	James	7	Manager	2
6	Steven	7	DevOps Engineer	2

Временные таблицы *рекурсивных общих табличных выражений* всегда ссылаются на результат последних вычислений, т.е. на данном этапе временная таблица **managers** ссылается на таблицу, состоящую из двух строк.

Теперь мы снова выбираем из базовой таблицы **employees** и временной таблицы те строки, у которых в столбцах **e.manager\_id** и **m.id** стоят одинаковые числа (в данном случае 5 и 6).

Таким образом

managers, вычисленная в рекурсивной части на 2-ой итерации

id	name	manager_id	job	level
=====				
2	Ben	5	Junior Developer	3
3	Barry	5	Intern	3
4	George	5	Developer	3
11	Leor	6	Data Scientist	3

Наконец все временные подтаблицы «склеиваются» и конструкция **SELECT \* FROM managers** возвращает таблицу **managers**

id	name	manager_id	job	level
=====				
7	Alice	1	VP	1 <i>--step 1</i>
-----				
5	James	7	Manager	2 <i>--step 2</i>
6	Steven	7	DevOps Engineer	2 <i>--step 2</i>
-----				
2	Ben	5	Junior Developer	3 <i>--step 3</i>
3	Barry	5	Intern	3 <i>--step 3</i>
4	George	5	Developer	3 <i>--step 3</i>
11	Leor	6	Data Scientist	3 <i>--step 3</i>

### 14.3. Изменение данных в WITH

В предложении **WITH** можно также использовать операторы, изменяющие данные (**INSERT**, **UPDATE** или **DELETE**). Это позволяет выполнять в одном запросе сразу несколько разных операций. Например

```
WITH moved_rows AS (
  DELETE FROM products
  WHERE
    dates >= '2010-10-01' AND
    dates < '2010-11-01'
  RETURNING *
)
INSERT INTO products_log (SELECT * FROM moved_rows);
```

Этот запрос фактически перемещает строки из таблицы **products** в таблицу **products\_log** (таблица должна уже существовать на момент выполнения запроса). Оператор **DELETE** удаляет указанные строки из **products** и возвращает их содержимое в предложении **RETURNING**, а затем главный запрос читает это содержимое и вставляет в таблицу **products\_log**.

## 15. Оконные функции

Помимо группировки и агрегирования, PostgreSQL предлагает еще один способ вычислений, затрагивающих несколько записей, – *оконные функции*. В случае группировки и агрегирования выводится одна запись для каждой группы входных записей. Оконные функции делают нечто похожее, но выполняются для каждой записи, а количество записей на входе и на выходе одинаковое.

При работе с оконными функциями группировка не обязательна, хотя и возможна. Оконные функции вычисляются *после группировки и агрегирования*. Поэтому в запросе **SELECT** они могут находиться только в списке выборки и во фразе **ORDER BY**.

### 15.1. Определение окна

Синтаксис оконных функций выглядит так

```
<function_name> (<function_arguments>)  
OVER (  
    [PARTITION BY <expression_list>]  
    [ORDER BY <order_by_list>]  
    [{ROWS | RANGE} <frame_start> |  
     {ROWS | RANGE} BETWEEN <frame_start> AND <frame_end>]  
)
```

Конструкция в скобках после слова **OVER** называется *определением окна*. Последняя его часть, начинающаяся словом **ROWS**, называется *определением фрейма*. Ключевое слово **OVER** делает агрегатную функцию оконной.

Набор записей, обрабатываемых оконной функцией, строится следующим образом. Вначале обрабатывается фраза **PARTITION BY**. Отбираются все записи, для которых выражения, перечисленные в списке **expression\_list**, имеют такие же значения, как и в текущей записи. Это множество строк называется *разделом* (partition). Текущая строка также включается в раздел. В общем-то, фраза **PARTITION BY** логически и синтаксически идентична фразе **GROUP BY**, только в ней запрещается ссылаться на выходные столбцы по именам или по номерам.

Иными словами, при обработке каждой записи оконная функция просматривает все остальные записи, чтобы понять, какие из них попадают в один раздел с текущей. Если фраза **PARTITION BY** отсутствует, то на данном шаге создается один раздел, содержащий все записи.

Далее раздел сортируется в соответствии с фразой **ORDER BY**, логически и синтаксически идентичной той же фразе в команде **SELECT**. И снова ссылки на выходные столбцы по имени или по номерам не допускаются. Если фраза **ORDER BY** опущена, то считается, что позиция каждой записи множества одинакова.

Наконец, обрабатывается определение фрейма. Это означает, что мы берем подмножество раздела, которое следует передать оконной функции. Оно и называется оконным фреймом. У фрейма есть начало и конец.

*Начало фрейма* может принимать следующие значения:

- **UNBOUNDED PRECEDING**: самая первая запись раздела,
- **<N> PRECEDING**: запись, предшествующая текущей в упорядоченном разделе и отстоящая от нее на **N** записей. Здесь **<N>** – целочисленное выражение, которое не может быть отрицательным и не может содержать агрегатные или другие оконные функции. **0 PRECEDING** указывает на текущую запись,

- **CURRENT ROW**: текущая строка,
- **<N> FOLLOWING**: запись, следующая за текущей в упорядоченном разделе и отстоящая от нее на N записей.

*Конец фрейма* может принимать следующие значения:

- **<N> PRECEDING**,
- **CURRENT ROW**,
- **<N> FOLLOWING**,
- **UNBOUNDED FOLLOWING**: последняя запись раздела.

Оконный фрейм можно определить в режиме **ROWS** или **RANGE**. Режим влияет на семантику **CURRENT ROW**. В режиме **ROWS** конструкция **CURRENT ROW** указывает на саму текущую запись, а в режиме **RANGE** – на первую или последнюю запись с такой же позицией, что у текущей, в смысле сортировки, заданной фразой **ORDER BY**.

В режиме **RANGE** в определении фрейма можно использовать варианты **BOUNDED . . .** или **CURRENT ROW**, но не **<N> PRECEDING**.

Если часть **frame\_end** опущена, предполагается **CURRENT ROW**. Если опущено все определение фрейма, то предполагается определение **RANGE UNBOUNDED PRECEDING**.

Например, конструкция

```
OVER (PARTITION BY a ORDER BY b ROWS BETWEEN UNBOUNDED PRECEDING AND 5 FOLLOWING)
```

означает, что для каждой строки раздел образуют все записи с одинаковым значением в поле **a**. Затем раздел сортируется в порядке возрастания поля **b**, а фрейм содержит все записи от первой до пятой после текущей строки.

## 15.2. Фраза WINDOWS

Определения окон могут быть довольно длинными, и часто использовать их в списке выборки неудобно. PostgreSQL предлагает способ определять и именовать окна, которые затем используются во фразе **OVER** оконной функции. Это делается с помощью фразы **WINDOW** команды **SELECT**, которая может находиться после фразы **HAVING**, например

```
SELECT count() OVER w, sum(b) OVER w, avg(b) OVER (w ORDER BY c ROWS BETWEEN 1 PRECEDING AND 1 FOLLOWING)
FROM table1
WINDOW w AS (PARTITION BY a) -- определение окна
```

Определенное таким образом окно можно использовать как есть. В примере выше функции **count** и **sum** так и делают. Но его можно и уточнить, как сделано в функции **avg**.

Синтаксически разница состоит в следующем: чтобы повторно использовать определение окна, имя этого окна следует указать после ключевого слова **OVER** без скобок. Если же мы хотим расширить определение окна, то имя окна следует указать внутри скобок.

## 15.3. Использование оконных функций

Все агрегатные функции, в т.ч. определенные пользователем, можно использовать как оконные, за исключением агрегатов по упорядоченным наборам и по гипотетическим наборам. На то, что функция выступает в роли оконной, указывает наличие фразы **OVER**.

Если агрегатная функция используется в качестве оконной, то она агрегирует строки, принадлежащие *оконному фрейму текущей строки*.

## Пример

```
-- общее табличное выражение выполняется перед главным запросом
WITH monthly_data AS ( -- CTE
    SELECT date_trunc('month', advertisement_date) AS month,
           count(*) AS cnt -- число строк для каждой группы
    FROM car_portal_app.advertisement
    GROUP BY date_trunc('month', advertisement_date)
    -- чтобы не дублировать записи во фразе SELECT и GROUP BY, во фразе GROUP BY
    -- можно сослаться на первый элемент из списка выборки по номеру
    -- т.е. можно было бы написать GROUP BY 1
)
SELECT
    to_char(month, 'YYYY-MM') AS month,
    cnt,
    sum(cnt) OVER ( -- накопительная сумма
        w ORDER BY month
    ) AS cnt_year,
    round(
        avg(cnt) OVER ( -- скользящее среднее
            ORDER BY month
            ROWS BETWEEN 2 PRECEDING AND 2 FOLLOWING
        ),
        1) AS mov_avg,
    -- для того чтобы деление было вещественным нужно, чтобы хотя бы один операнд
    -- был приведен к вещественному типу
    -- round работает только с типом numeric
    round((cnt::numeric / sum(cnt) OVER w) * 100, 2) AS ratio_year -- здесь sum(cnt) вычисляется
    для всего раздела без учета порядка следования записей в таблице
FROM monthly_data -- обращение к результату работы CTE
WINDOW w AS (PARTITION BY date_trunc('year', month)); -- определение окна
```

## Выведет

month	cnt	cnt_year	ratio_year
2014-01	42	42	5.78
2014-02	49	91	6.74
2014-03	30	121	4.13
2014-04	57	178	7.84
2014-05	106	284	14.58
2014-06	103	387	14.17
...			

Здесь общее табличное выражение вычисляется перед главным запросом, так как имя временной таблицы `monthly_data`, связанной с CTE, присутствует в главном запросе. Результат кешируется и используется повторно.

Сначала, как обычно вычисляются объекты, указанные в предложении `FROM`, т.е. в данном случае таблица `advertisement` (дополнительно указана схема базы данных `car_portal_app`). Группировка выполняется по временной метке «усеченной» до месяца (т.е. в формате '2020-07-01 00:00:00+03').

В предложение `SELECT` конструкция, указанная во фразе `GROUP BY`, включается полностью, без изменений и связывается с псевдонимом `month`. Как известно, в список выборки фразы `SELECT` в случае группировки могут включаться только атрибуты, указанные в `GROUP BY` и агрегатные функции.

Результат работы общего табличного выражения будет доступен через имя `monthly_data`.

Переходим к главному запросу. Здесь читается временная таблица `monthly_data` и из нее выбираются атрибуты, перечисленные в списке выборки. Функция `to_char` преобразует временную метку к формату `'YYYY-MM'` и связывается с псевдонимом `month`. Атрибут `cnt` выбирается как есть, без изменений.

Далее, первая оконная функция `sum` использует окно `w`, описанное с помощью ключевого слова `WINDOW` и расширенное `ORDER BY`. Определение фрейма в данном случае опущено, поэтому предполагается фрейм `RANGE BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW`. Следовательно, функция вычисляет сумму значений по всем записям, начиная с начала года и до текущего месяца включительно, т.е. накопительный итог за год.

Вторая функция `avg` для каждой записи вычисляет скользящее среднее по пяти записям – две предшествующие, текущая и две последующие. Ранее определенное окно не используется, потому что при вычислении скользящего среднего год не принимается во внимание, важен только порядок записей.

Третья оконная функция `sum` пользуется тем же определением окна `w`. Вычисленная ею сумма значений за год является знаменателем в выражении, которое дает вклад текущего месяца в сумму. Очень важный момент заключается в том, что в данном случае фраза `ORDER BY` опущена и это значит, что накопительная сумма вычисляется независимо от порядка следования записей в таблице, и потому возвращается только одно число, равное накопительной сумме по разделу, а не как в первом случае вычисления накопительной суммы (там использовалась фраза `ORDER BY`).

---

#### Замечание

В агрегатной функции `count` можно использовать ключевое слово `DISTINCT`, чтобы вывести только уникальные строки; например,

```
SELECT count(*), count(DISTINCT name_id) FROM table;
```

---

Существует ряд *оконных функций*, не являющихся *агрегатными*. Они служат для получения значений других записей в разделе, для вычисления ранга текущей записи относительно остальных и для генерации номеров строк.

Изменим предыдущий отчет, будет считать, что требуется вычислить две разности: между количеством объявлений в текущем месяце и предыдущем месяце того же года и в том же месяце прошлого года, а также ранг текущего месяца. Вот как выглядит подзапрос

```
WITH monthly_data AS ( -- CTE, выполняется прежде главного запроса
    SELECT date_trunc('month', advertisement_date) AS month,
           count(*) AS cnt
    FROM car_portal_app.advertisement
    GROUP BY date_trunc('month', advertisement_date)
)
SELECT to_char(month, 'YYYY-MM') AS month,
       cnt,
       cnt - lag(cnt) OVER (ORDER BY month) AS prev_m,
       cnt - lag(cnt,12) OVER (ORDER BY month) AS prev_y,
       rank() OVER (w ORDER BY cnt DESC) AS rank
FROM monthly_data
WINDOW w AS (PARTITION BY date_trunc('year', month))
ORDER BY month DESC;
```

Выведет

```
+-----+-----+-----+-----+
| month | cnt | prev_m | prev_y | rank |
+-----+-----+-----+-----+
| 2017-01 | 1 | 0 | 0 | 1 |
| 2017-02 | 1 | 0 | 0 | 2 |
| 2017-03 | 1 | 0 | 0 | 3 |
| 2017-04 | 1 | 0 | 0 | 4 |
| 2017-05 | 1 | 0 | 0 | 5 |
| 2017-06 | 1 | 0 | 0 | 6 |
| 2017-07 | 1 | 0 | 0 | 7 |
| 2017-08 | 1 | 0 | 0 | 8 |
| 2017-09 | 1 | 0 | 0 | 9 |
| 2017-10 | 1 | 0 | 0 | 10 |
| 2017-11 | 1 | 0 | 0 | 11 |
| 2017-12 | 1 | 0 | 0 | 12 |
| 2018-01 | 1 | 1 | 0 | 13 |
| 2018-02 | 1 | 1 | 0 | 14 |
| 2018-03 | 1 | 1 | 0 | 15 |
| 2018-04 | 1 | 1 | 0 | 16 |
| 2018-05 | 1 | 1 | 0 | 17 |
| 2018-06 | 1 | 1 | 0 | 18 |
| 2018-07 | 1 | 1 | 0 | 19 |
| 2018-08 | 1 | 1 | 0 | 20 |
| 2018-09 | 1 | 1 | 0 | 21 |
| 2018-10 | 1 | 1 | 0 | 22 |
| 2018-11 | 1 | 1 | 0 | 23 |
| 2018-12 | 1 | 1 | 0 | 24 |
| 2019-01 | 1 | 1 | 1 | 25 |
| 2019-02 | 1 | 1 | 1 | 26 |
| 2019-03 | 1 | 1 | 1 | 27 |
| 2019-04 | 1 | 1 | 1 | 28 |
| 2019-05 | 1 | 1 | 1 | 29 |
| 2019-06 | 1 | 1 | 1 | 30 |
| 2019-07 | 1 | 1 | 1 | 31 |
| 2019-08 | 1 | 1 | 1 | 32 |
| 2019-09 | 1 | 1 | 1 | 33 |
| 2019-10 | 1 | 1 | 1 | 34 |
| 2019-11 | 1 | 1 | 1 | 35 |
| 2019-12 | 1 | 1 | 1 | 36 |
| 2020-01 | 1 | 1 | 1 | 37 |
| 2020-02 | 1 | 1 | 1 | 38 |
| 2020-03 | 1 | 1 | 1 | 39 |
| 2020-04 | 1 | 1 | 1 | 40 |
| 2020-05 | 1 | 1 | 1 | 41 |
| 2020-06 | 1 | 1 | 1 | 42 |
| 2020-07 | 1 | 1 | 1 | 43 |
| 2020-08 | 1 | 1 | 1 | 44 |
| 2020-09 | 1 | 1 | 1 | 45 |
| 2020-10 | 1 | 1 | 1 | 46 |
| 2020-11 | 1 | 1 | 1 | 47 |
| 2020-12 | 1 | 1 | 1 | 48 |
| 2021-01 | 1 | 1 | 1 | 49 |
| 2021-02 | 1 | 1 | 1 | 50 |
| 2021-03 | 1 | 1 | 1 | 51 |
| 2021-04 | 1 | 1 | 1 | 52 |
| 2021-05 | 1 | 1 | 1 | 53 |
| 2021-06 | 1 | 1 | 1 | 54 |
| 2021-07 | 1 | 1 | 1 | 55 |
| 2021-08 | 1 | 1 | 1 | 56 |
| 2021-09 | 1 | 1 | 1 | 57 |
| 2021-10 | 1 | 1 | 1 | 58 |
| 2021-11 | 1 | 1 | 1 | 59 |
| 2021-12 | 1 | 1 | 1 | 60 |
```



2015-02	9	-39	-40	2
2015-01	48	11	6	1
2014-12	37	1	<NULL>	10
2014-11	36	-10	<NULL>	11
2014-10	46	-36	<NULL>	8
2014-09	82	12	<NULL>	3
...				

Функция `lag` возвращает значение указанного выражения для записи, отстоящей на заданное число записей (по умолчанию 1) назад от текущей записи. Другими словами, функция `lag` просто сдвигает значения в столбце на заданное число записей *вниз*, замещая отсутствующие значения в верхней части с помощью `<NULL>`.

Пример

```
-- здесь создается один раздел, упорядоченные по столбцу 'n'
SELECT n,
       lag(n) OVER (ORDER BY n) AS shift
FROM generate_series(10,15) AS t(n);
```

Выведет

n	shift
10	<NULL>
11	10
12	11
...	

Как видно, в феврале 2015 года опубликовано 9 объявлений – на 39 меньше, чем в январе 2015.

Функция `rank` возвращает ранг текущей строки внутри раздела. Имеется в виду ранг с промежутками, т.е. в случае, когда две записи занимают одинаковую позицию в порядке, заданном фразой `ORDER BY`, обе получают одинаковый ранг, а следующая получает ранг на две единицы больше. То есть у нас будет две первые записи и одна третья.

Перечислим другие оконные функции:

- `lead`: аналогична `lag`, но возвращает значения выражения, вычисленное для записи, отстоящей от текущей на указанное количество записей вперед, т.е. сдвигает элементы столбца вверх, замещая отсутствующие значения в нижней части с помощью `<NULL>`,
- `first_value`, `last_value`, `nth_value`: возвращает значения выражения, вычисленные соответственно для первой, последней и *n*-ой записи,
- `row_number`: возвращает номер текущей строки в разделе,
- `dense_rank`: возвращает ранг текущей строки без промежутков (плотный ранг),
- `percent_rank` и `cume_dist`: возвращает относительный ранг текущей строки. Разница между функциями состоит в том, что в первой числителем дроби является ранг, а во второй – номер строки,
- `ntile`: делит раздел на заданное количество равных частей и возвращает номер части, в которую попала текущая строка.

## 16. Продвинутые методы работы с SQL

### 16.1. Выборка первых записей

Часто бывает необходимо найти первые записи относительно какого-то критерия. Допустим, к примеру, что в базе данных `car_portal` нужно найти первое объявление для каждого идентификатора `car_id` в таблице `advertisement`.

```
SELECT
    advertisement_id,
    advertisement_date,
    adv.car_id,
    seller_account_id
FROM
    car_portal_app.advertisement AS adv
INNER JOIN
    (SELECT
        car_id,
        min(advertisement_date) AS min_date
    FROM
        car_portal_app.dvertisement
    GROUP BY car_id) AS first
ON adv.car_id = first.car_id
AND adv.advertisement_date = first.min_date;
```

Но если логика упорядочения настолько сложна, что для ее реализации функции `min` недостаточно, то такой подход работать не будет. Проблему могут решить оконные функции, но они не всегда удобны

```
SELECT DISTINCT
    first_value(advertisement_id) OVER w AS advertisement_id,
    min(advertisement_date) OVER w AS advertisement_date,
    car_id,
    first_value(seller_account_id) OVER w AS seller_account_id
FROM
    car_portal_app.advertisement
WINDOW w AS (PARTITION BY car_id ORDER BY advertisement_date);
```

PostgreSQL предлагает явный способ выбрать первую запись из каждой группы – ключевое слово `DISTINCT ON`. Для каждой уникальной комбинации значений из списка выражений команды `SELECT` возвращает только первую запись. Для определения того, что такое «первая» запись, служит фраза `ORDER BY`

```
SELECT DISTINCT ON (car_id) advertisement_id, advertisement_date, car_id, seller_account_id
FROM car_portal_app.advertisement
ORDER BY car_id, advertisement_date;
```

Другой пример. Пусть дана следующая таблица

month	cnt
2014-01-10 00:00:00	42
2014-02-10 00:00:00	49
2014-03-10 00:00:00	30
2014-04-10 00:00:00	57
2014-05-10 00:00:00	106
2014-06-10 00:00:00	103
2014-07-10 00:00:00	69

```
| 2014-08-10 00:00:00 | 70 |
| 2014-09-10 00:00:00 | 82 |
| 2014-10-10 00:00:00 | 46 |
| 2014-11-10 00:00:00 | 36 |
| 2014-12-10 00:00:00 | 37 |
| 2015-01-10 00:00:00 | 48 | <- первая фраза раздела
| 2015-02-10 00:00:00 | 9 |
+-----+-----+
```

Требуется из каждой группы, сформированной по году, выбрать первую запись. Записи упорядочиваются по атрибуту month

```
SELECT DISTINCT ON (date_trunc('year', month)) cnt, to_char(month, 'YYYY-MM') AS month
FROM monthly_data;
```

Выведет

```
+-----+-----+
| cnt | month |
+-----+-----+
| 42 | 2014-01 |
| 48 | 2015-01 |
+-----+-----+
```

То есть конструкция DISTINCT ON выполняет группировку по указанному атрибуту. И фраза ORDER BY не обязательна.

## 17. Пользовательские типы данных

В PostgreSQL есть два способа определить пользовательский тип данных:

- о команда CREATE DOMAIN: позволяет создавать пользовательские типы данных с ограничениями с целью сделать исходный код более модульным,
- о команда CREATE TYPE: часто используется для создания составного типа, что полезно в процедурных языках, где такие типы служат для возврата значений. Эта же команда может создавать тип ENUM, позволяющий уменьшить количество соединений со справочными таблицами.

Объекты доменов, как и другие объекты базы данных, должны иметь уникальные имена в пределах схемы. Основное применение доменов – в качестве образцов. Рассмотрим, к примеру, текстовый тип, который не может принимать значение NULL и содержать пробелы. Это образец.

```
first_name TEXT NOT NULL,
last_name TEXT NOT NULL,
CHECK(first_name !~ '\s' AND last_name !~ '\s')
```

Вместо ограничений можно создать домен

```
CREATE DOMAIN text_without_space_and_null AS TEXT NOT NULL CHECK (value !~ '\s');
```

Теперь этот домен можно использовать при создании таблиц

```
CREATE TABLE test_domain(
    test_att text_without_space_and_null
);
```

Домен можно изменить командой ALTER DOMAIN. Если в домен добавляется новое ограничение, то все атрибуты, определенные с помощью этого домена, будут проверены на соблюдение

этого ограничения. При желании проверку старых значений можно подавить, а затем почистить таблицы вручную. Допустим, что мы хотим добавить в домен `text_without_space_and_not_null` ограничение на длину текста

```
ALTER DOMAIN text_without_space_and_null ADD CONSTRAINT text_without_space_and_null_length_chk
CHECK (length(value) <= 15);
```

Эта команда завершиться неудачно, если какой-нибудь атрибут, принадлежащий этому домену, длиннее 15 символов. Если мы хотим все же применить ограничение к новым данным, а старые пока оставить как есть, то это можно сделать

```
-- указание NOT VALID допускается только для ограничений CHECK
ALTER DOMAIN text_without_space_and_null
ADD CONSTRAINT
-- указывается имя ограничения
text_without_space_and_null_length_chk CHECK (length(value) <= 15) NOT VALID;
```

После вычистки старых данных можно будет проверить для них ограничение, выполнив команду `ALTER DOMAIN ... VALIDATE CONSTRAINT`.

```
ALTER DOMAIN
text_without_space_and_null -- имя существующего домена
VALIDATE CONSTRAINT
text_without_space_and_null_length_chk; -- имя ограничения
```

Наконец, метакоманда `psql \dD+` выводит описание домена.

Составные типы данных очень полезны для создания функций, особенно когда возвращаемый тип представляет собой строку из нескольких значений. Например, нам нужна функция, возвращающая `seller_id`, `seller_name`, количество объявлений и полный ранг продавца. Создадим новый тип

```
CREATE TYPE seller_information AS (seller_id INT, seller_name TEXT, number_of_advertisements
BIGINT, total_rank FLOAT);
```

Воспользуемся новым типом данных для возврата значения из функции

```
CREATE OR REPLACE FUNCTION seller_information(account_id INT)
RETURNS seller_information AS
$$
SELECT seller_account.seller_account_id, first_name || last_name AS seller_name, count(*), sum(
rank)::float/count(*)
FROM account
INNER JOIN
seller_account ON account.account_id = seller_account.account_id
LEFT JOIN
advertisement ON advertisement.seller_account_id = seller_account.seller_account_id
LEFT JOIN
advdvertisement_rating ON advertisement.advertisement_id = advertisement_rating.
advertisement_id
WHERE account.account_id = $1
GROUP BY seller_account.seller_account_id, first_name, last_name
$$ LANGUAGE sql;
```

Команду `CREATE TYPE` можно использовать также для определения перечисления `ENUM`

```
-- создать составной тип
CREATE TYPE rank AS ENUM ('poor', 'fair', 'good', 'very good', 'excellent');
-- вывести описание типа перечисления
SELECT enum_range(null::rank);
```

Теперь в столбец с типом **rank** можно будет вставить только значение из списка, указанного в описании типа **rank**.

## 18. Работа со строками и регулярные выражения

Больше информации про строковые функции и операторы можно найти на страницах официальной документации PostgreSQL по ссылке <https://postgrespro.ru/docs/postgrespro/9.6/functions-string>.

Пусть дана таблица **employees** вида

id	name	salary	job	manager_id
1	John	10000	CEO	
2	Ben	1400	Junior Developer	5
3	Barry	500	Intern	5
4	George	1800	Developer	5
5	James	3000	Manager	7
6	Steven	2400	DevOps Engineer	7
7	Alice	4200	VP	1
8	Jerry	3500	Manager	1
9	Adam	2000	Data Analyst	8
10	Grace	2500	Developer	8
11	Leor	50000	Data Scientist	6

Выбрать те строки из столбца **job**, в которых содержатся строковые значения, удовлетворяющие шаблону `'_ata %'`, означающий, что первый символ строки может быть любым, а после пробелов может не быть ни одного символа или быть сколько угодно символов. То есть символ «`_`» совпадает с любым символом, а символ «`%`» совпадает с произвольным количеством символов. Здесь используется предложение **LIKE**, которое чувствительно к регистру. В качестве альтернативного варианта можно использовать предложение **ILIKE**<sup>3</sup>, которое не учитывает регистр.

```
SELECT * FROM employees WHERE job LIKE '_ata %';
```

Выведет

id	name	salary	job	manager_id
9	Adam	2000	Data Analyst	8
11	Leor	50000	Data Scientist	6

Подобные задачи можно решать и с помощью предложения **SIMILAR TO**, которое похоже на **LIKE**, но в отличие от последнего при интерпретации шаблонов использует определение регулярного выражения стандарта **SQL**. Регулярные выражения **SQL** – это смесь нотации предложения **LIKE** и нотации регулярных выражений.

Шаблоны и **LIKE**, и **SIMILAR TO** должны соответствовать *всей* строке целиком, что, вообще говоря, не согласуется с концепцией обычных регулярных выражений, когда шаблон может соответствовать любой части строки.

**SIMILAR TO**, как и **LIKE** использует символ «`_`» и символ «`%`», что соответствует `.` и `*` в регулярных выражениях **POSIX**. Дополнительно поддерживаются символы `|` (указывает альтернативные варианты), `*` (указывает, что стоящий слева элемент повторяется ноль или более раз), `+` (указывает, что стоящий слева элемент повторяется один или более раз), `(...)` (могут использоваться

<sup>3</sup>Это расширение PostgreSQL, которое не имеет отношения к стандарту SQL

для указания групп), а [...] (определяют символьный класс как в POSIX). Однако ? и {...} не поддерживаются и кроме того «.» не является метасимволом.

Символ «\» экранирует метасимволы, т.е. «снимает» их специальное значение. Другой символ для экранирования можно задать с помощью предложения **ESCAPE**.

Рассмотренную выше задачу можно решить с помощью **SIMILAR TO** следующим образом

```
SELECT * FROM employees WHERE job SIMILAR TO '_ata (A/S)%';
```

Здесь символ «%», означающий произвольную последовательность символов, обязателен, так как шаблоны **SIMILAR TO** должны совпадать со *всей строкой*.

Очень полезна бывает функция **substring()**. Как и **SIMILAR TO** шаблон должен совпадать со всей строкой, например

```
SELECT name, job FROM employees  
WHERE substring(job from '%#"Dev#"%' for '#')='Dev';
```

Последовательность символов **"...#" задают левую и правую скобки группы** (можно указать и какой-то другой символ в качестве скобки, например, **:"...:"**, но его нужно указать в ... for ':'). Последовательность, попавшая между этих символов будет возвращена. Как и раньше символы «%» здесь нужны для того чтобы шаблон совпадал со всей строкой.

Обрезать строку можно так

```
SELECT name, job, substring(job,1,4) FROM employees;
```

Здесь первое число – позиция элемента строки (нумерация начинается с единицы), а второе число – число элементов подстроки, которое нужно оставить в выводе.

Эквивалентная конструкция

```
SELECT name, job, substring(job from 1 for 4) FROM employees;
```

Очень гибкое решение дают *регулярные выражения* POSIX (Portable Operating System Interface – переносимый интерфейс операционных систем). Например для того чтобы выбрать, как и в рассмотренном выше примере, всех, кто имеет отношение к работе с данными, можно использовать такую конструкцию

```
SELECT * FROM employees WHERE job ~* 'data .*';
```

Здесь **~\*** – оператор соответствию шаблону *без* учета регистра. Если нужно учесть регистр, то используется оператор **~**.

Аналогично **!~** – оператор несоответствия шаблону с учетом регистра, оператор **!~\*** – оператор несоответствия шаблону *без* учета регистра.

Регулярные выражения могут совпадать с строкой в любом месте (не обязательно со всей строкой).

Еще пример. Нужно выбрать строки из столбца **job**, в которых последовательность символов **dev** стоит в начале строки («**^**» – якорь начала строки)

```
select * from employees where job ~* '^dev.*';
```

Пример с положительной проверкой вперед

```
select * from employees where job ~* '(?=engineer)';
```

Выведет

id	name	salary	job	manager_id
6	Steven	2400	DevOps Engineer	7
20	Alex	25050	Data Engineer	10

У регулярных выражений есть один тонкий нюанс, связанный с «жадностью» квантификатора. Рассмотрим пример

```
SELECT substring('xy1234z', 'y*(\d{1,3})'); -- вернет '123'
```

Здесь используется «жадный» квантификатор \*. В общем случае этот квантификатор соответствует элементу, который не повторяется ни разу или повторяется произвольное число раз, однако в данном случае он соответствует строго единственному символу 'y' (больше в строке символов 'y' нет). Другими словами подшаблон y\* жадно забирает символ 'y' и на этом успокаивается, так как больше ничего от этой последовательности взять не сможет. А затем подшаблон \d{1,3} жадно забирает 3 цифры, так как ему никто не мешает это сделать.

Но если использовать «нежадный» вариант квантификатора \*?, то картина изменится

```
SELECT substring('xy1234z', 'y?(\d{1,3})'); -- вернет '1'
```

Вариант, когда подстрока не имеет ни одного элемента устраивает подшаблон y\*? (потому что используется нежадный квантификатор), но не устраивает подшаблон \d{1,3}, согласно которому в последовательности должна быть хотя бы одна цифра. Приходится как бы «тянуть» подшаблон y\*? вправо, потому что нежадный квантификатор стремится схлопнуться в пустое начало строки. Таким образом, на 2-ой итерации курсор сдвигается вправо на один символ и теперь указывает на 'x'. Нежадный подшаблон y\*? удовлетворен (ему достаточно и пустой подстроки), но не удовлетворен второй подшаблон. Курсор передвигается еще на один элемент вправо. И теперь указывает на 'y' (подстрока: 'xy'). Нежадный подшаблон y\*? снова удовлетворен, но подшаблон \d{1,3} все еще не содержит ни одной цифры, поэтому курсор снова перемещается вправо еще на один элемент. В этот раз подстрока выглядит как 'xy1', что удовлетворяет и первый, и второй подшаблоны, но подшаблон y\*? больше бы устроил вариант, когда подстрока пустая. С другой стороны подшаблон \d{1,3} требует, чтобы в подстроке была хотя бы одна цифра, поэтому подстрока вида 'xy1' (в группу попадает только 1) – это компромисс.

---

#### Замечание

Удобно представлять, что *нежадные квантификаторы* типа \*? представляют собой пружинки сжатия, которые тянут влево и в самом простом случае довольствуются пустой последовательностью, а *жадные квантификаторы* (\*) можно представлять как пружинки растяжения, которые стремятся занять всю последовательность и с неохотой уступают элементы

---

## 19. Программирование на PL/pgSQL

### 19.1. Примеры работы с функциями

Требуется построить текстовое представление ранга объявления

```
CREATE OR REPLACE FUNCTION cast_rank_to_text (rank INT) RETURNS TEXT AS
$$
DECLARE -- объявление переменных
    rank_result TEXT;
```

```

BEGIN -- область видимости
    IF rank = 5 THEN rank_result = 'Excellent';
    ELSIF rank = 4 THEN rank_result = 'Very Good';
    ELSIF rank = 3 THEN rank_result = 'Fair';
    ELSIF rank = 2 THEN rank_result = 'Poor';
    ELSE rank_result = 'No such rank';
    END IF;
    RETURN rank_result;
END;
$$ LANGUAGE plpgsql;

SELECT n, cast_rank_to_text(n) FROM generate_series(1,6) AS t(n);

```

К слову, если бы этот код находился в отдельном файле, например, `sql_query.sql`, то его можно было запустить и посмотреть результат в терминале так

```
psql -U postgres -d postgres -c '\! chcp 1251' -f sql_query.sql
```

ВЫВЕДЕТ

```

+---+-----+
| n | cast_rank_to_text |
+---+-----+
| 1 | No such rank      |
| 2 | Poor              |
| 3 | Fair              |
| 4 | Very Good         |
| 5 | Excellent         |
| 6 | No such rank      |
+---+-----+

```

Рассмотренную выше задачу можно решить и с помощью конструкции CASE

```

CREATE OR REPLACE FUNCTION cast_rank_to_text (rank INT) RETURNS TEXT AS
$$
DECLARE
    rank_result TEXT;
BEGIN
    CASE rank
        WHEN 5 THEN rank_result = 'Excellent';
        WHEN 4 THEN rank_result = 'Very Good';
        WHEN 3 THEN rank_result = 'Good';
        WHEN 2 THEN rank_result = 'Fair';
        WHEN 1 THEN rank_result = 'Poor';
        ELSE rank_result = 'No such rank';
    END CASE;
    RETURN rank_result;
END; $$ LANGUAGE plpgsql;

```

Важно отметить, что в этой форме CASE запрещено сопоставление со значением NULL, потому что результатом сравнения с NULL является NULL. Чтобы обойти это ограничение, можно воспользоваться второй формой и задать условие сопоставления явно

```

...
WHEN rank IS NULL THEN RAISE EXCEPTION 'Rank should be not NULL';
...

```



## 19.2. Итерирование

Итерирование позволяет повторять блок команд. При этом часто требуется определить начальную точку и условие окончания. В PostgreSQL есть несколько команд для обхода результатов запроса и организации циклов: LOOP, CONTINUE, EXIT, FOR, WHILE и FOR EACH.

Самая простая команда выглядит так

```
[ <<label>> ]
LOOP
    statements
END LOOP [ label ];
```

Для демонстрации перепишем функцию factorial\_psql

```
DROP FUNCTION IF EXISTS factorial_psql (fact INT);
CREATE OR REPLACE FUNCTION factorial_psql (fact INT) RETURNS BIGINT AS
$$
DECLARE -- область объявления переменных
    result BIGINT = 1;
BEGIN -- область видимости функции
    IF fact = 1 THEN RETURN 1;
    ELIF fact IS NULL OR fact < 1 THEN RAISE EXCEPTION 'Provide a positive integer';
    ELSE
        LOOP
            result = result*fact;
            fact = fact - 1;
            EXIT WHEN fact = 1;
        END LOOP;
    END if;
    RETURN result;
END; $$ LANGUAGE plpgsql;

SELECT n, 'fact('||n||')' || ' -> ' || factorial_psql(n) AS result
FROM (VALUES (3),(5),(8)) AS t(n); -- источником данных выступает виртуальная таблица
```

Выведет

```
+---+-----+
| n |      result      |
+---+-----+
| 3 | fact(3) -> 6     |
| 5 | fact(5) -> 120    |
| 8 | fact(8) -> 40320  |
+---+-----+
```

Здесь условная команда EXIT предотвращает заикливание. После выполнения EXIT управление передается команде, следующей за LOOP. Для управления выполнением команд внутри цикла LOOP PL/pgSQL предоставляет также команду CONTINUE, которая похожа на EXIT, только вместо выхода из цикла передает управление на его начало, пропуская код, оставшийся до конца цикла.

---

### Замечание

Рекомендуется избегать команд CONTINUE и EXIT, особенно в середине блока, потому что они нарушают порядок выполнения, что затрудняет чтение кода

---

Команда WHILE продолжает выполнять блок команд, пока истинно заданное условие. Вот ее синтаксис

```
[ <<label>> ]
```

```
WHILE boolean-expression LOOP
    statements
END LOOP [ label ];
```

Ниже мы печатаем дни текущего месяца в цикле WHILE

```
DO $$
DECLARE -- область объявления переменных
    first_day_in_month date := date_trunc('month', current_date)::date;
    last_day_in_month date := (
        date_trunc('month', current_date) + '1 month - 1 day'::interval
    )::date;
    counter date := first_day_in_month;
BEGIN -- область видимости
    WHILE (counter <= last_day_in_month) LOOP
        RAISE NOTICE '%', counter;
        counter := counter + '1 day'::interval;
    END LOOP;
END; $$ LANGUAGE plpgsql;
```

В PL/pgSQL есть две формы команды FOR, предназначенные для:

- о обход строк, возвращенных SQL-запросом;
- о обхода диапазона целых чисел.

Синтаксис команды FOR представлен ниже:

```
[ <<label>> ]
FOR name IN [ REVERSE ] expression1 .. expression2 [ BY expression ] LOOP
    statements
END LOOP [ label ];
```

Здесь **name** – имя локальной переменной типа **integer**. Областью видимости этой переменной является цикл FOR. Команды внутри цикла могут ее *читать*, но не могут изменять. Но это поведение можно изменить, определив переменную в секции объявлений объемлющего блока. Выражения **expression1** и **expression2** должны иметь целые значения. Если **expression1** равно **expression2**, то цикл FOR выполняется только один раз.

Ключевое слово **REVERSE** необязательно; оно определяет порядок, в котором генерируется диапазон (возрастающий или убывающий). Если слово **REVERSE** опущено, то **expression1** должно быть меньше **expression2**, иначе цикл не выполнится ни разу. Наконец, ключевое слово **BY** задает шаг между двумя последовательными числами; следующее за ним выражение **expression** должно быть положительным целым числом. В показанном ниже цикле FOR производится обход диапазона отрицательных чисел в обратном порядке и печатаются значения -1, -3, ..., -9

```
DO $$ -- анонимная функция
BEGIN
    FOR j REVERSE -1 .. -10 BY 2 LOOP
        RAISE NOTICE '%', j;
    END LOOP;
END; $$ LANGUAGE plpgsql;
```

Синтаксис цикла для обхода результатов запроса несколько иной

```
[ <<label>> ]
FOR target IN query LOOP
    statements
END LOOP [ label ];
```

Локальная переменная `target` объявлена в объемлющем блоке. Она необязательно должна быть примитивного типа, скажем, `INTEGER` или `TEXT`, допускается также составной тип и тип `RECORD`. В PL/pgSQL обходить можно результат выполнения курсора или команды `SELECT`. Курсор – это специальный объект, инкапсулирующий запрос `SELECT` и позволяющий читать результаты по нескольким строкам за раз. В следующем примере печатаются имена всех баз данных

```
DO $$
DECLARE
    database RECORD;
BEGIN
    FOR database IN SELECT * FROM pg_database LOOP
        RAISE NOTICE '%', database.datname;
    END LOOP;
END; $$ LANGUAGE plpgsql;
```

Здесь конструкция `SELECT * FROM pg_database` возвращает набор строк, содержащих информацию о базах данных PostgreSQL. Каждая строка, возвращенная запросом, связывается с переменной цикла `database`, а затем выбирается значение атрибута `datname`.

### 19.3. Возврат из функции

Команда возврата завершает функцию и передает управление вызывающей стороне. Существует несколько разновидностей команды возврата: `RETURN`, `RETURN NEXT`, `RETURN QUERY`, `RETURN QUERY EXECUTE` и т.д. Команда `RETURN` может возвращать *одно значение* или *множество*.

```
DO $$
BEGIN
    RETURN; -- по достижении этого места функция завершает работу
    RAISE NOTICE 'This statement will not be executed';
END; $$ LANGUAGE plpgsql;
```

Тип `VOID` используется, когда смысл функции заключается в побочных эффектах, например записи в журнал. Встроенная функция `pg_sleep` задерживает выполнение серверного процесса на заданное число секунд.

Тип возвращаемого значения может быть базовым, составным, доменным или псевдотипом. Показанная ниже функция возвращает представление учетной записи в формате JSON

```
-- sql
CREATE OR REPLACE FUNCTION car_portal_app.get_account_in_json (account_id INT)
RETURNS JSON AS $$
    SELECT row_to_json(account)
    FROM car_portal_app.account
    WHERE account_id = $1;
$$ LANGUAGE sql;

-- plpgsql
CREATE OR REPLACE FUNCTION car_portal_app.get_account_in_json (acc_id INT)
RETURNS JSON AS
$$
BEGIN
    -- если возвращается одна строка, то просто RETURN!!!
    RETURN (SELECT row_to_json(account)
            FROM car_portal_app.account
            WHERE account_id = acc_id);
END; $$ LANGUAGE plpgsql;
```

Для возврата нескольких строк используются функции, возвращающие множества. Строка может иметь базовый тип (например, `integer`), составной, табличный, доменный или псевдотип. Функция, *возвращающая множество*, помечается ключевым словом `SETOF`

```
-- sql
CREATE OR REPLACE FUNCTION car_portal_app.car_model(model_name TEXT)
RETURNS SETOF car_portal_app.car_model AS
$$
SELECT car_model_id, make, model
FROM car_portal_app.car_model
WHERE model = model_name;
$$ LANGUAGE sql;

-- plpgsql
CREATE OR REPLACE FUNCTION car_portal_app.car_model(model_name TEXT)
RETURNS SETOF car_portal_app.car_model AS $$
BEGIN
    RETURN QUERY SELECT car_model_id, make, model FROM car_portal_app.car_model
    WHERE model = model_name;
END; $$ LANGUAGE plpgsql;
```

Если для возвращаемого значения еще нет типа, то можно [1, стр. 214]:

- определить и использовать новый тип данных,
- использовать тип `TABLE`,
- использовать выходные параметры и тип данных `RECORD`.

Пусть требуется вернуть только поля `car_model_id` и `make`, и соответствующий тип данных не определен. Тогда предыдущую функцию можно переписать в виде

```
CREATE OR REPLACE car_portal_app.car_model(model_name TEXT)
RETURNS TABLE (car_model_id INT, make TEXT) AS $$
BEGIN
    -- если возвращается множество строк, то RETURN QUERY!!!
    RETURN QUERY SELECT car_model_id, make FROM car_portal_app.car_model
    WHERE model = model_name;
END; $$ LANGUAGE plpgsql;
```

## 19.4. Обработка исключений

Для перехвата и возбуждения исключений в PostgreSQL предназначены команды `EXCEPTION` и `RAISE`. Ошибки возникают при нарушении ограничений целостности данных или при выполнении недопустимых операций, например: присваивание текста целому числу, деление на нуль, присваивание переменной значения вне допустимого диапазона и т.д. По умолчанию любая ошибка в PL/pgSQL-функции приводит к прерыванию выполнения и откату изменений. Чтобы восстановиться, можно перехватить ошибку с помощью фразы `EXCEPTION`, синтаксически очень похожей на блоки в PL/pgSQL. Кроме того, ошибки можно возбуждать в команде `RAISE`. Пример

```
CREATE OR REPLACE FUNCTION check_not_null (value anyelement) RETURNS VOID AS
$$
BEGIN
    IF (value IS NULL) THEN
        RAISE EXCEPTION USING ERRCODE = 'check_violation';
    END IF;
END; $$ LANGUAGE plpgsql;
```

Полиморфная функция `check_not_null` просто возбуждает ошибку, в которой состояние `SQLSTATE` содержит строку `check_violation`. Если вызвать эту функцию, передав ей `NULL` в качестве аргумента, то возникнет ошибка.

Чтобы можно было точно узнать, когда и почему возникло исключение, в PostgreSQL определено несколько категорий кодов ошибок. Например, если пользователь возбудил исключение, не указав `ERRCODE`, то `SQLSTATE` будет содержать строку `P001`, а если нарушено ограничение уникальности, то строку `23505`.

Для определения причины ошибки в команде `EXCEPTION` можно сравнивать `SQLSTATE` или название условия

```
WHEN unique_violation THEN ...
WHEN SQLSTATE '23505' THEN ...
```

Наконец, при возбуждении ошибки можно задать сообщение об ошибке и `SQLSTATE`, памятуя о том, что код ошибки `ERRCODE` должен содержать 5 цифр и / или букв в кодировке ASCII, но не должен быть равен 00000, например

```
DO $$
BEGIN
  RAISE EXCEPTION USING ERRCODE = '1234X', MESSAGE = 'test customized SQLSTATE: ';
  EXCEPTION WHEN SQLSTATE '1234X' THEN RAISE NOTICE '% %', SQLERRM, SQLSTATE;
END; $$ LANGUAGE plpgsql;
```

Для демонстрации перехвата исключений перепишем функцию `factorial` так, чтобы она возвращала `NULL`, если передан аргумент `NULL`

```
DROP FUNCTION IF EXISTS factorial (INT);
CREATE OR REPLACE FUNCTION factorial(fact INT) RETURNS BIGINT AS
$$
BEGIN
  PERFORM check_not_null(fact);
  IF fact > 1 THEN RETURN factorial(fact - 1)*fact;
  ELSIF fact IN (0,1) THEN RETURN 1;
  ELSE RETURN NULL;
  END IF;

  EXCEPTION
    WHEN check_violation THEN RETURN NULL;
    WHEN OTHERS THEN RAISE NOTICE '% %', SQLERRM, SQLSTATE;
END; LANGUAGE plpgsql;
```

Если теперь вызвать

```
SELECT * FROM factorial(NULL::INT); -- вернет NULL
```

Функция `factorial` не возбудила ошибку, поскольку она была перехвачена в команде `EXCEPTION` и вместо нее возвращено `NULL`. Обратите внимание, что сравнивается не `SQLSTATE`, а имя условия. Специальное имя условия `OTHERS` соответствует любой ошибке, оно часто используется, чтобы перехватить неожиданные ошибки.

## 19.5. Динамический SQL

Динамический SQL служит для построения и выполнения запросов «на лету». В отличие от статической команды SQL, полный текст динамической команды заранее неизвестен и может

меняться от выполнения к выполнению. Допускаются команды подязыков DDL, DCL и DML. Динамический SQL позволяет сократить объем однотипных задач.

Еще одно очень важное применение динамического SQL – устранение побочных эффектов кеширования в PL/pgSQL, поскольку запросы, выполняемые с помощью команды EXECUTE, *не кешируются*.

Для реализации динамического SQL предназначена команда EXECUTE. Она принимает и интерпретирует строку. Синтаксис этой команды показан ниже

```
EXECUTE command-string [ INTO [STRICT] target ] [ USING expression [, ...] ];
```

**Динамическое выполнение команд DDL** Иногда бывает необходимо выполнить операции на уровне объектов базы данных: таблиц, индексов, столбцов, ролей и т.д. Например, после развертывания таблицы с целью обновления статистики часто производят ее очистку и анализ. Так для анализа таблиц из схемы `car_portal_app` можно было бы написать такой скрипт

```
-- VACUUM не может использоваться в функциях
DO $$ -- анонимная функция
DECLARE -- область определения переменных
    table_name text;
    schema_name text := 'bookings';
BEGIN -- область видимости
    FOR table_name IN (SELECT tablename FROM pg_tables
                       WHERE schemaname = schema_name) LOOP
        RAISE NOTICE 'Analyzing %', table_name;
        EXECUTE 'ANALYZE ' || schema_name || '.' || table_name;
        -- или так: EXECUTE format('ANALYZE %I.%I', schema_name, table_name);
    END LOOP;
END; $$ LANGUAGE plpgsql;
```

**Динамическое выполнение команд DML** Некоторые приложения работают с данными интерактивно. Например, ежемесячно могут генерировать данные для выставления счетов. Бывает и так, что приложение фильтрует данные на основе критерия, заданного пользователем. Для таких задач очень удобен динамический SQL. Пример

```
CREATE OR REPLACE FUNCTION get_lines(predicate TEXT)
    RETURNS TABLE(name VARCHAR, job VARCHAR) AS
$$
DECLARE
    table_name TEXT := 'employees';
BEGIN
    RETURN QUERY EXECUTE 'SELECT name, job FROM table_name WHERE ' || predicate;
END; $$ LANGUAGE plpgsql;
```

Протестируем

```
SELECT * FROM get_lines('id IN (1, 10, 15)');
```

**Динамический SQL и кеширование** Как уже было сказано, PL/pgSQL *кеширует планы выполнения*. Это хорошо, если сгенерированный план статический. Например, для следующей команды ожидается, что всегда будет использоваться просмотр индекса благодаря его избирательности. В таком случае кеширование плана экономит время и повышает производительность.

Но бывает и по-другому. Предположим, что построен индекс по столбцу `advertisement_date`, и мы хотим получить количество объявлений, начиная с некоторой даты. Для чтения записей из таблицы `advertisement_date` можно применить как просмотр индекса, так и последовательный просмотр. Все зависит от избирательности индекса. Кеширование плана выполнения такого запроса может создать серьезные проблемы.

Для решения проблемы можно переписать функцию, указав в качестве языка SQL, или оставить PL/pgSQL, но воспользоваться командой `EXECUTE` (тогда план выполнения запроса не будет кешироваться)

```
-- с помощью $1, $2 и пр. можно передавать ТОЛЬКО значения!!!
-- для динамической подстановки имен таблиц, столбцов и пр. служит функция format()
CREATE OR REPLACE FUNCTION car_portal_app.get_advertisement_count(some_date timestampz)
RETURNS BIGINT AS
$$
DECLARE
    count BIGINT;
BEGIN
    -- запросы EXECUTE не кешируются!!!
    EXECUTE 'SELECT count(*) FROM car_portal_app.advertisement
            WHERE advertisement_date >= $1'
    USING some_date -- символ $1 ссылается на значения в предложении USING
    INTO count; -- число строк, возвращенное запросом, связывается с переменной count
    RETURN count;
END; $$ LANGUAGE plpgsql;
```

## 20. Массивы

Массив состоит из набора элементов (значений или переменных), порядок массива важен, каждый элемент идентифицируется своим индексом. Индексы элементов начинаются с 1. Все элементы массива должны иметь один и тот же тип, например `INT`, `TEXT` и т.п.

Поддерживаются также многомерные массивы. В массивах PostgreSQL допускаются дубликаты и значения `NULL`.

Инициализируем одномерный массив и получим первый элемент

```
SELECT ('{red,blue,green}'::text[])[1]; -- red
```

По умолчанию длина массива не задается, но ее можно указать, когда массивы используются для определения отношения. По умолчанию индексирование массива начинается с единицы, но и это поведение можно изменить, определив размерность на этапе инициализации

```
SELECT ('[0:2]={red,blue,green}'::text[])[1] AS color; -- blue
```

Пример

```
-- сначала создаем массив, а затем можно обращаться к его элементам
WITH test AS ( -- общее табличное выражение
    SELECT '[0:1]={10,20}'::int[] AS arr
)
SELECT arr, arr[0] FROM test;
```

Выведет

```
+-----+-----+
|      arr      | arr |
+-----+-----+
```

```
| [0:1]={10,20} | 10 |
+-----+-----+
```

Для инициализации массива используется конструкция {}. Но есть и другой способ

```
SELECT array['red', 'green', 'blue'] AS primary_colors;
```

PostgreSQL предоставляет много функций для манипулирования массивами, например `array_remove` для удаления элемента. Ниже продемонстрированы некоторые функции массивов:

```
SELECT
  array_ndims(two_dim_array) AS "Number of dimensions",
  array_dims(two_dim_array) AS "Dimensions index range",
  array_length(two_dim_array, 1) AS "The array length of 1st dimension",
  cardinality(two_dim_array) AS "Number of elements",
  two_dim_array[1][1] AS "The first element"
FROM
  (VALUES ('{ {red,green,blue}, {red,green,blue} }'::text[] [])) AS foo(two_dim_array);
```

выведет (предварительно нужно задать в `psql \x`)

```
+-[ RECORD 1 ]-----+-----+
| Number of dimensions      | 2      |
| Dimensions index range    | [1:2][1:3] |
| The array length of 1st dimension | 2      |
| Number of elements        | 6      |
| The first element         | red     |
+-----+-----+
```

Распространенное применение массивов – моделирование многозначных атрибутов. Также они используются для моделирования хранилищ ключей и значений. Для этого заводят два массива: один содержит ключи, другой – значения, а для связывания ключа со значением используется индекс массива.

Так, в таблице `pg_stats` этот подход применим для хранения информации о гистограмме типичных значений. В столбцах `most_common_vals` и `most_common_freqs` хранятся, соответственно, типичные значения в некотором столбце и частоты этих значений, как показано в примере ниже

```
SELECT tablename, attname, most_common_vals, most_common_freqs
FROM pg_stats
WHERE array_length(most_common_vals, 1) < 10 AND schemaname NOT IN
      ('pg_catalog', 'information_schema') LIMIT 1;
```

Для того чтобы передать функции произвольное число аргументов, следует использовать ключевое слово `VARIADIC`. Например

```
CREATE OR REPLACE null_count (VARIADIC arr int[]) RETURNS INT AS
$$
  SELECT count(CASE WHEN m IS NOT NULL THEN 1 ELSE NULL END)::int
  FROM unnest($1) AS m(n)
$$ LANGUAGE sql;
```

Пример использования

```
SELECT null_count(NULL, 5, NULL, 10); -- 2
SELECT * FROM null_count(VARIADIC '{NULL,1}'::int[]); -- 1
```

Еще один пример работы с массивами

```
SELECT substring('python',1,i) FROM generate_series(1,length('python')) AS g(i);
```



ВЫВЕДЕТ

```
+-----+
| substring |
+-----+
| p         |
| py        |
| pyt       |
| pyth      |
| pytho     |
| python    |
+-----+
```

Теперь можно обернуть этот вывод массивом

```
SELECT
  array(SELECT substring('python',1,i)
        FROM generate_series(1,length('python')) AS g(i)
        )::text[];
```

ВЫВЕДЕТ

```
+-----+
|          array          |
+-----+
| {p,py,pyt,pyth,pytho,python} |
+-----+
```

## 20.1. Функции и операторы массивов

Для массивов, как и для других типов данных, определены операторы. Например, оператор = сравнивает на равенство, а оператор || производит конкатенацию. Операторы @> и <@ возвращают истину, если левый массив содержит в правом или содержится соответственно

```
SELECT '{2,5,10}'::int[] @> '{2}'::int[]; --t
SELECT '{42}'::int[] <@ '{2,42,100}'::int[]; --t
```

Элементы, попавшие в одну группу, можно представить в виде массива с помощью функции array\_agg.

Функция ANY аналогична конструкции SQL IN() и служит для проверки принадлежности

```
SELECT 1 IN (1,2,3), 1 = ANY ('{1,2,3}'::int[]);
```

## 20.2. Доступ к элементам массива и их модификация

К элементу массива обращаются по индексу; если элемент с указанным индексом не существует, то возвращается значение NULL:

```
CREATE TABLE colors(
  color text[]
);

INSERT INTO colors(color) VALUES ('{red,green}'::text[]);
INSERT INTO colors(color) VALUES ('{red}'::text[]);
```

Что теперь храниться в таблице?

```
-- в данном случае нумерация начинается с 1
SELECT color[2] FROM colors;
```

ВЫВЕДЕТ

```
+-----+
| color |
+-----+
| green |
| <NULL>|
+-----+
```

Чтобы получить булеву маску для столбца `color` выполним такой запрос

```
SELECT
  color[2] IS NOT DISTINCT FROM ('{green}':text[])[1]
  -- или просто
  -- color[2] IS NOT DISTINCT FROM 'green'
FROM colors;
```

вернет

```
+-----+
| ?column? |
+-----+
| t        |
| f        |
+-----+
```

Можно получить срез массива, указав верхнюю и нижнюю границы

```
-- если индексов нет в массиве, то вернется пустой массив {}
SELECT color[1:2] FROM colors;
```

Обновить можно массив целиком, срез массива или отдельный элемент. Можно также дописать элементы в конец массива, воспользовавшись оператором конкатенации `||`

```
SELECT array['red', 'green'] || '{blue}':text[] AS append;
```

Для удаления всех элементов с указанным значением предназначена функция `array_remove`

```
SELECT array_remove('{Ansys,Nastran,Abaqus}':text[], 'Ansys');
```

ВЫВЕДЕТ

```
+-----+
| array_remove |
+-----+
| {Nastran,Abaqus} |
+-----+
```

Чтобы удалить элемент по индексу, можно воспользоваться фразой `WITH ORDINALITY`

```
SELECT array(
  SELECT unnest
  FROM unnest('{Ansys,Nastran,Abaqus}':text[])
  WITH ordinality
  WHERE ordinality <> 1
);
```

Здесь функция `unnest` преобразует массив в последовательность строк. Конструкция `WITH ORDINALITY` создает еще один столбец с именем `ordinality`, который по сути просто задает номера строк. В предложении `WHERE` выбираются те строки, у которых номера не равны 1. В список выборки включается только столбец `unnest`, который создается функцией `unnest`.

## 20.3. Индексирование массивов

Для индексирования массивов используется GIN-индекс. В стандартном дистрибутиве PostgreSQL имеется класс операторов GIN для одномерных массивов. GIN-индекс поддерживают следующие операторы:

- оператор содержит @>,
- оператор содержится в <@,
- пересекается &&,
- оператор сравнения на равенство =.

GIN-индекс по столбцу `color` создается следующим образом

```
CREATE INDEX ON colors USING GIN(color);
```

Чтобы заставить просматривать индекс, следует

```
postgres=> SET enable_seqscan TO off;
postgres=> EXPLAIN SELECT * FROM colors WHERE '{red}'::text[] && color;
```

## 21. Хранилище ключей и значений

Хранилище ключей и значений, или ассоциативный массив, – очень популярная структура данных в современных языках программирования. Имеются также базы данных, специально заточенные под эту структуру данных, например Redis.

PostgreSQL поддерживает хранилище ключей и значений – `hstore`. Расширение `hstore` дает в руки разработчику лучшее из обоих миров, оно предлагает дополнительную гибкость, не жертвуя функциональностью PostgreSQL.

Кроме того, `hstore` позволяет моделировать *слабоструктурированные данные* и *разреженные массивы*, оставаясь в рамках реляционной модели.

Для создания расширения `hstore` нужно выполнить следующую команду от имени супер-пользователя

```
CREATE EXTENSION hstore;
```

Текстовое представление `hstore` содержит нуль или более пар `key=>value`, разделенных запятой, например

```
postgres=# SELECT 'tires=>"winter tires", seat=>leather'::hstore;
```

Выведет

```
+-----+
|          hstore          |
+-----+
| "seat"=>"leather", "tires"=>"winter tires" |
+-----+
```

Можно также сгенерировать одиночное значение в `hstore` с помощью функции `hstore(key, value)`

```
SELECT hstore('CAE-package', 'Ansys');
```

Выведет

```
+-----+
|      hstore      |
+-----+
| "CAE-package"=>"Ansys" |
+-----+
```

Все ключи в хранилище `hstore` должны быть уникальны. Однако у `hstore` есть ограничение:

- это не настоящее хранилище документов, поэтому представить в нем вложенные объекты трудно,
- управление множеством ключей, поскольку ключи в `hstore` чувствительны к регистру.

Чтобы получить значение ключа, используйте оператор `->`. Для добавления в `hstore` служит оператор конкатенации `||`, а для удаления пары ключ-значение – оператор `-`. Для обновления хранилища `hstore` следует конкатенировать его с другим экземпляром `hstore`, который содержит новое значение.

```
CREATE TABLE features(
    feature hstore
);
```

```
-- вставить в виртуальную таблицу пару <<ключ : значение>>
-- и вернуть эту пару с помощью RETURNING
postgres=# INSERT INTO features(feature) VALUES ('Engine=>Diesel')::hstore RETURNING *;
```

```
-- добавить новую пару <<ключ : значение>>
UPDATE features SET feature = feature || 'Seat=>Lether')::hstore RETURNING *;
```

```
-- обновление значения для ключа, существующего в хеш-таблице, аналогично добавлению пары
-- если ключ есть в хеш-таблице, то его значение обновляется
UPDATE features SET feature = feature || 'Engine=>Petrol')::hstore RETURNING *;
```

```
-- удаление ключа
UPDATE features SET feature = feature - 'Seat')::text RETURNING *;
```

Тип данных `hstore` преобразуется во множество с помощью функции `each(hstore)`, и это открывает перед разработчиком возможность применять к `hstore` все операции реляционной алгебры, например, `DISTINCT`, `GROUP BY` и `ORDER BY`.

```
-- получить уникальные ключи
SELECT DISTINCT (each(feature)).key FROM features;
```

```
-- получить пары
SELECT DISTINCT (each(feature)).* FROM features;
```

Выведет

```
+-----+-----+
|    key    |   value   |
+-----+-----+
| CAE-package | Ansys      |
| Language    | IronPython |
| Solver type | Direct     |
+-----+-----+
```

## 21.1. Индексирование hstore

Для индексирования данных типа **hstore** можно воспользоваться индексами GIN и GIST, а какой именно выбрать зависит от ряда факторов: количества строк в таблице, наличного места, требуемой производительности поиска и обновления по индексу, характера запросов и т.д.

Прежде чем остановится на том или ином индексе, нужно провести тщательное эталонное тестирование.

Сначала создадим GIN-индекс для выборки записи по ключу

```
CREATE INDEX ON features USING GIN(feature);
```

Проверить содержит ли хранилище заданный ключ можно с помощью оператора **?**, вывести значение по ключу с помощью оператора **->** (поддерживаются только одинарные кавычки)

```
-- выводит значения по заданному ключу для тех строк, в которых хранится хеш-таблица, в которой
    содержится ключ 'Language'
SELECT feature->'Language'
FROM features
WHERE feature ? 'Language';
```

```
-- выводит значения по заданному ключу для тех строк, в которых есть хеш-таблица с ключом '
    Solver' и значением, которое начинается на 'dir'
SELECT feature->'Solver'
FROM features
WHERE feature->'Solver' ~* 'dir.*';
```

Еще пример на использование оператора **->**

```
CREATE TABLE hstore_doc(
    id serial primary key,
    doc hstore
);
INSERT INTO hstore_doc(doc) VALUES ('"solver type"=>direct,"package name"=>Ansys,language=>
    IronPython');
INSERT INTO hstore_doc(doc) VALUES ('"solver type"=>iterative,"package name"=>Nastran,language=>
    C++'::hstore);
INSERT INTO hstore_doc(doc) VALUES ('language=>Java,"package name"=>Abaqus')
SELECT -- при обращении по ключу поддерживаются только одинарные кавычки
    doc->'solver type' AS "solver type",
    doc->'package name' AS "package name"
FROM hstore_doc;
```

ВЫВЕДЕТ

```
+-----+-----+
| solver type | package name |
+-----+-----+
| direct      | Ansys        |
| iterative   | Nastran      |
| <NULL>      | Abaqus       |
+-----+-----+
```

Пример на использование оператора **?**

```
SELECT
    doc->'solver type' AS "solver type",
    doc->'package name' AS "package name"
FROM hstore_doc
WHERE doc ? 'solver type'; -- те строки, в которых есть хранилище с ключом 'solver type'
```

Разумеется, если некоторый оператор не поддерживает GIN-индексом, как, например, оператор `->`, можно использовать и индекс типа B-tree

```
CREATE INDEX ON features ((feature->'Engine'))
```

```
SELECT feature->'Engine'
FROM features
WHERE feature->'Engine' = 'Diesel'; -- значение, возвращенное по заданному ключу,
                                     -- сравнивается с 'Diesel'
```

## 22. Структура данных JSON

JSON – универсальная структура данных, понятная как человеку, так и машине. Она поддерживается почти всеми современными языками программирования и повсеместно применяется в качестве формата обмена данными в REST-совместимых веб-службах.

### 22.1. JSON и XML

И XML, и JSON используются для определения структуры данных передаваемых документов. Грамматически JSON проще, чем XML, вследствие чего JSON-документы компактнее и проще для чтения и написания.

### 22.2. Типы данных JSON в PostgreSQL

PostgreSQL поддерживает два типа JSON: `JSON` и `JSONB`, тот и другой реализуют спецификацию RFC 7159. Оба типа применимы для контроля правил JSON. Они почти идентичны, но `JSONB` эффективнее, потому что является двоичным форматом и поддерживает индексы.

При работе с типом JSON рекомендуется задавать для базы данных кодировку UTF8, чтобы обеспечить его совместимость со стандартом RFC 7159. Документ, сохраняемый как объект типа JSON, хранится в текстовом формате. Если же объект храниться как `JSONB`, то примитивные типы JSON – `string`, `boolean`, `number` – отображаются, соответственно, на типы `text`, `Boolean` и `numeric`.

### 22.3. Доступ к объектам типа JSON и их модификация

Если текст приводится к типу `json`, то он сохраняется и отображаются без какой-либо обработки, поэтому сохраняются все пробелы, форматирование чисел и другие детали. В формате `jsonb` эти детали не сохраняются.

JSON-объекты могут содержать вложенные JSON-объекты, массивы, вложенные массивы, массивы JSON-объектов и т.д. Глубина вложенности произвольна, так что можно конструировать весьма сложные JSON-документы. В одном массиве JSON-документа могут находиться элементы разных типов

```
SELECT '{
  "name" : "John",
  "Address" : {"Street" : "Some street",
               "city" : "Some city"},
  "rank" : [5,3,4,5,2,3,4,5]
}'::jsonb;
```

Можно получить поле JSON-объекта в виде JSON-объекта или текста. К полям можно также обращаться по индексу или по имени поля:

- -> (для JSON), ->> (для текста): возвращает поле JSON-объекта по индексу или по имени поля,
- #> (для JSON), #>> (для текста): возвращает поле JSON-объекта по указанному пути.

Пример

```
CREATE TABLE json_doc( doc jsonb );
INSERT INTO json_doc SELECT
  '{ "name" : "John",
    "Address" : {
      "Street" : "Some street",
      "city" : "Some city"
    },
    "rank" : [5,3,4,5,2,3,4,5]
  }'::jsonb;
```

Если требуется вернуть города

```
SELECT doc->'Address'->>'city', doc#>>'{Address,city}' FROM json_doc;
```

Вставить в JSON-объект пару ключ-значение

```
UPDATE json_doc SET doc = jsonb_insert(doc, '{hobby}', '["swim", "read"]', true) RETURNING *;
```

А вот так изменяется существующая пара ключ-значение

```
UPDATE json_doc SET doc = jsonb_set(doc, '{hobby}', '["read"]', true) RETURNING *;
```

И наконец, удалим пару ключ-значение

```
UPDATE json_doc SET doc = doc - 'hobby' RETURNING *;
```

## 22.4. Индексирование JSON-документов

Для индексирования JSONB-документов используется GIN-индекс, который поддерживает следующие операторы:

- @>: содержит ли JSON-документ в левой части значение в правой части,
- ? : существует ли указанный ключ в JSON-документе,
- ?&: существует ли в JSON-документе хотя бы один из элементов текстового массива,
- ?|: существуют ли в JSON-документе все элементы текстового массива (ключи).

Содержит ли JSON-объект указанную пару «ключ-значение»

```
SELECT '{ "package name" : "Ansys", "solver type" : "direct" }'::jsonb @> '{ "package name" : "Ansys" }'::jsonb; -- t
```

JSON-документ можно преобразовать во множество с помощью функции `json_to_record()`. Это полезно, потому что позволяет сортировать данные, как в обычных хранилищах. Кроме того, можно агрегировать данные из нескольких строк и сконструировать массив JSON-объектов с помощью функции `json_agg()`.

## 23. PostgreSQL и Python

### 23.1. Простой пример работы с PostgreSQL через библиотеки SQLAlchemy и psycopg2

Пример работы с базой данных при помощи библиотеки psycopg2

```
import psycopg2

conn_info = {
    'user' : 'postgres',
    'dbname' : 'demo',
    'port' : 5432
}

# создаем соединение с базой данных
conn = psycopg2.connect(**conn_info)

# создаем объект-курсор
cur = conn.cursor()

# выполняем запрос
cur.execute('''
    SELECT count(*), count(DISTINCT fare_conditions)
    FROM ticket_flights
''')

# выводим результат работы SQL-запроса
cur.fetchall() # [(1045726, 3)]

# если сейчас попытаться извлечь лишь первую строку результата, то вывод будет пустым
cur.fetchone()

# чтобы все-таки вывести первую строку, требуется повторить выборку
cur.execute('SELECT count(*), count(DISTINCT fare_conditions) FROM ticket_flights')
cur.fetchone() # (1045726, 3)
```

Пример работы с базой данных при помощи библиотеки sqlalchemy

```
import sqlalchemy
import pandas as pd

engine = sqlalchemy.create_engine('postgresql://postgres@localhost:5432/demo')

# создаем соединение
conn = engine.connect(); conn # <sqlalchemy.engine.base.Connection at 0xd732088>

# выполняем запрос
conn.execute('''
    SELECT count(*), count(DISTINCT fare_conditions)
    FROM ticket_flights
''').fetchall() # [(1045726, 3)]

# и тут же, без повторного выполнения запроса можно извлечь только первую строку результата
conn.execute('''
    SELECT count(*), count(DISTINCT fare_conditions)
    FROM ticket_flights
''').fetchone() # (1045726, 3)

conn.execute('''
```



```

SELECT fare_conditions, max(amount)
FROM ticket_flights
GROUP BY 1
''').fetchall()
# [('Business', Decimal('203300.00')),
#  ('Comfort', Decimal('47600.00')),
#  ('Economy', Decimal('74500.00'))]

conn.execute('''
SELECT fare_conditions, max(amount)
FROM ticket_flights
GROUP BY 1
''').fetchone()
# ('Business', Decimal('203300.00'))

pd.read_sql('''
select fare_conditions, max(amount)
from ticket_flights
group by 1;''',
engine) # обязательно нужно передать ранее созданный движок или соединение
# fare_conditions      max
# 0      Business    203300.0
# 1      Comfort     47600.0
# 2      Economy     74500.0

```

К слову, еще с помощью библиотеки `sqlalchemy` можно работать, например, с распределенным аналитическим хранилищем больших данных [Apache Kylin](#)

```

import sqlalchemy
import pandas as pd
import matplotlib.pyplot as plt

kylin_engine = sqlalchemy.create_engine('kylin://<username>:<password>@1<IP>:<PORT>/<
project_name>', connect_args={'timeout' : 60})
sql = '''
SELECT movieid, count(DISTINCT userid) AS COUNT_USERS
FROM userratings
GROUP BY movieid
ORDER BY count(DISTINCT userid) DESC
LIMIT 15
'''

moviecount = pd.read_sql(sql, kylin_engine)

df = moviecount.sort_values(by='COUNT_USERS', ascending=False, na_position='first')
...

```

Пример на динамическое конструирование SQL-запросов

```

import sqlalchemy

engine = sqlalchemy.create_engine('postgresql://postgres@localhost:5432/demo')
conn = engine.connect()
# динамическое построение запроса
conn.execute("SELECT * FROM {} WHERE prog_lang ~* '{}'".format('caepackage_test', '~py.*'))

# но вставка значений в таблицу возможно только через параметры метода 'execute'
conn.execute('INSERT INTO test_cae(id, name) VALUES (%(id)s, %(name)s)',
              {'id' : 1, 'name' : 'Ansys'}) # параметры, заданные с помощью словаря
)
conn.execute('INSERT INTO test_cae(id, name) VALUES (%s, %s)',

```

## 24. Приемы работы в pgAdmin 4

## 25. Приемы работы в psql

`psql` – это терминальный клиент для работы с PostgreSQL. Утилита `psql` предоставляет ряд метакоманд и различные возможности, подобные тем, что имеются у командных оболочек, для облегчения написания скриптов и автоматизации широкого спектра задач.

### 25.1. Конфигурационный файл

Поведением интерактивного терминала `psql` можно управлять с помощью конфигурационного файла `~/.psqlrc`. На ОС Windows этот файл располагается по адресу `C:\Users\ADM\AppData\Roaming\postgresql` и называется `psqlrc.conf`.

Конфигурационный файл утилиты `psql` может включать следующие настройки

`psqlrc.conf`

```
\set QUIET 1
\timing
\pset border 2
\pset null <NULL>
\set ON_ERROR_STOP on
\setenv PSQL_EDITOR "C:\Program Files\Git\usr\bin\vim.exe"
\set VERBOSITY verbose
\set QUIET 0
```

### 25.2. Метакоманды psql

`\c` или `\connect`: устанавливает новое подключение к серверу PostgreSQL. Параметры подключения можно указывать как позиционно, так и передавая аргумент.

Например

```
=> \c "host=localhost port=5432 dbname=mydb connect_timeout=10 sslmode=disable"
=> \c postgresql://tom@localhost/mydb?application_name=myapp
```

`\cd`: сменяет текущий рабочий каталог на заданный. Без аргументов устанавливает домашний каталог пользователя.

`\conninfo`: выводит информацию о текущем подключении к базе данных.

`\copy`: производит копирование данных с участием клиента. При этом выполняются SQL-команда `COPY`, но вместо чтения или записи в файл на сервере, `psql` читает или записывает файл и пересылает данные между сервером и локальной файловой системой. Это означает, что для доступа к файлам используются привелегии локального пользователя, а не сервера, и не требуются привелегии суперпользователя SQL. Синтаксис команды похож на синтаксис SQL-команды `COPY`. Все параметры, кроме источника и получателя данных, соответствуют параметрам `COPY`. Альтернативный способ получить тот же результат, что и с `\copy ... to` – использовать SQL-команду `COPY ... TO STDOUT` и завершить ее командой `\g name`.

`\d[S+]`: для каждого отношения (таблицы, представления, материализованного представления, индекса, последовательности, внешней таблицы) или составного типа, соответствующих шаблону, показывает все столбцы, их типы, табличное пространство и любые специальные атрибуты, такие как NOT NULL или значения по умолчанию. Также показываются связанные индексы, ограничения, правила и триггеры.

`\da[S]`: выводит список агрегатных функций вместе с типом возвращаемого значения и типами данных, которыми они оперируют.

`\dD[S+]`: выводит список доменов.

`\dL[S+]`: выводит список процедурных языков.

`\dn[S+]`: выводит список схем (пространств имен).

`\encoding`: устанавливает кодировку набора символов на клиенте. Без аргументов команда показывает текущую кодировку.

`\!`: выполняет команду операционной системы.

### 25.3. Примеры использования

Вывести список таблиц, присутствующих в базе данных `postgres`, предварительно задав кодовую страницу, соответствующую Windows-кодировке

```
$ psql -U postgres -d postgres -c '\! chcp 1251' -c '\d'
```

Вывести первые 5 строк таблицы `aircrafts` из базы данных `demo`, организовав вывод строк в вертикальном формате (`\x`; эквивалентно ключу `psql -x`)

```
$ psql -U postgres -d demo -c '\x' -c 'TABLE aircrafts LIMIT 5;'
```

Выполнить вычисления факториала для чисел 5, 8 и 12, результат представить в виде таблицы из пар «число - факториал\_от\_числа», а затем результат выполнения запроса записать в csv-файл

```
psql -U postgres -d postgres
-c '\! chcp 1251'\ -- настройка кодовой страницы
-c 'DROP TABLE IF EXISTS fact_t;'\
-c 'CREATE TABLE fact_t AS
  SELECT n, factorial(n) AS fact
  FROM (VALUES (5), (8), (12)) AS t(n);'\
-c "COPY fact_t TO 'E:/[WorkDirectory]/GARBAGE/fact_out.csv' WITH (FORMAT csv);"
```

Загрузить файл `gemini_ethusd_d.csv` в подготовленную таблицу `gemini`

```
psql -U postgres -d postgres
-- создать таблицу в текущей БД
-c 'CREATE TABLE gemini (
  date timestamp,
  symbol text not null,
  open real not null,
  high real not null,
  low real not null,
  close real not null,
  volume_eth real not null,
  volume_usd real not null
  PRIMARY KEY (date));'
-- записать в подготовленную таблицу csv-файл
-c "COPY gemini FROM 'E:/.../gemini_ethusd_d.csv' WITH (HEADER true, FORMAT csv);"
```

---

### Замечание

Лучше для нескольких команд использовать несколько ключей `-c`

---

Прочитать команды из файла `sql_query.sql`, а не из стандартного ввода. По большому счету ключ `-f` равнозначен метакоманде `\i`

```
$ psql -U postgres -f sql_query.sql
```

Вывести первые 3 строки таблицы в HTML-формате (`-H`)

```
$ psql -U postgres -d postgres -H -c '! chcp 1251' -c 'table family limit 3;'
```

Записать вывод результатов всех запросов в файл с именем `psql_output.txt`

```
$ psql -U postgres -d postgres -H -c '! chcp 1251' -c 'table family limit 3;' \
-o psql_output.txt
```

Вывести таблицу в формате  $\text{\LaTeX}$  и вывод запроса записать в файл `for_latex_output.txt`

```
$ psql -U postgres -d postgres -P format=latex \
-c '! chcp 1251' -c 'table family limit 3;' \
-o for_latex_output.txt
```

## 26. Специальные функции и операторы

### 26.1. Предикаты ANY, ALL

Использование `IN` эквивалентно `= ANY`, а использование `NOT IN` эквивалентно `<> ALL`. Пример

```
-- есть ли совпадение хотя бы с одним элементом массива?
SELECT 'test'::text = ANY('{"test","non-test"}'::text[]); -- true
-- есть ли совпадение со всеми элементами массива?
SELECT 'test'::text = ALL('{"test","non-test"}'::text[]); -- false
```

### 26.2. Оператор конкатенации

Соединить два массива можно с помощью оператора `||`

```
SELECT '{2,3,10}'::int[] || '{5}'::int[]; -- {2,3,10,5}
```

С помощью этого же оператора можно «склеивать» строки

```
SELECT name || '[' || job || ']' AS record FROM employees; -- Ben[ Junior Developer ]
```

К слову, у PostgreSQL нестрогая типизация. То есть PostgreSQL проводит неявное преобразование типов, например, когда используется оператор конкатенации, склеивающий строку и число, то выполняется неявное преобразование числового типа в строковый.

### 26.3. Диапазонные операторы

Подробнее вопрос обсуждается в документации PostgreSQL [9.19. Диапазонные функции и операторы](#).

С помощью оператора `@>` удобно проверять покрывает ли диапазон слева от оператора диапазон справа от оператора

```
SELECT '{2,3,5}'::int[] @> '{3}'::int[] -- true
```

Можно проверить содержит ли диапазон слева от оператора элемент справа от оператора

```
SELECT '[2011-01-01,2011-03-01]'::tsrange @> '2011-01-10'::timestamp; --true
```

Еще можно с помощью оператора @> работать с json-объектами

```
-- здесь предполагается, что атрибут 'model' имеет тип 'jsonb'
-- вывести значения по указанному ключу в соответствующих строках
SELECT
    aircraft_code,
    model->'en' AS model
FROM
    aircrafts_data
WHERE
    model->'en' @> '"Airbus A321-200"'::jsonb;
```

Выведет

```
+-----+-----+
| aircraft_code |      model      |
+-----+-----+
| 321          | "Airbus A321-200" |
+-----+-----+
```

То есть во фразе WHERE мы выбираем те строки, у которых в json-объектах атрибута model, есть ключ 'en', имеющий значение 'Airbus A321-200'. А затем во фразе SELECT выбираем только значения по указанному ключу в этих строках.

Если требуется выяснить содержится ли элемент в диапазоне, то используется оператор <@

```
SELECT 42 <@ int4range(2,10); --false
-- принадлежит ли 3 полуотрезку [2,10)
SELECT 3 || ' in ' || int4range(2,10) AS cond, 3 <@ int4range(2,10) AS bool; --true
```

Общие элементы (пересечение) удобно выявлять с помощью оператора &&

```
SELECT '{3}'::int[] && '{2,3,5}'::int[]; --true
```

## 26.4. Функции, генерирующие ряды значений

Очень полезна бывает функция generate\_series(start, stop, step), которая возвращает последовательность в общем случае вещественных чисел от start до stop с заданным шагом step

```
SELECT generate_series(1.1, 4, 1.3) AS real_num;
```

Выведет

```
+-----+
| real_num |
+-----+
|      1.1 |
|      2.4 |
|      3.7 |
+-----+
(3 строки)
```

Сгенерировать несколько временных меток с шагом в 5 часов

```
SELECT generate_series('2020-05-01 00:00'::timestamp,
                      '2020-05-01 22:00'::timestamp,
                      '5 hours'::interval) AS dates;
```

ВЫВЕДЕТ

```
+-----+
|      dates      |
+-----+
| 2020-05-01 00:00:00 |
| 2020-05-01 05:00:00 |
| 2020-05-01 10:00:00 |
| 2020-05-01 15:00:00 |
| 2020-05-01 20:00:00 |
+-----+
(5 строк)
```

Все функции, упомянутые во фразе **FROM**, могут использовать результаты любых предшествующих функций или подзапросов (указанных в этой же фразе **FROM**)

```
SELECT a, b
FROM
    generate_series(1,3) AS a,
    generate_series(a,a+2) AS b;
```

ВЫВЕДЕТ

```
+---+---+
| a | b |
+---+---+
| 1 | 1 |
| 1 | 2 |
| 1 | 3 |
| 2 | 2 |
| 2 | 3 |
| 2 | 4 |
| 3 | 3 |
| 3 | 4 |
| 3 | 5 |
+---+---+
(9 строк)
```

Когда после функции в предложении **FROM** добавляется **WITH ORDINALITY**, в выходные данные добавляется столбец типа **bigint**, числа в котором начинаются с 1 и увеличиваются на 1 для каждой строки, выданной функцией. Пример

```
SELECT * FROM pg_ls_dir('.') WITH ORDINALITY AS t(ls, n) LIMIT 5;
```

ВЫВЕДЕТ

```
+-----+---+
|      ls      | n |
+-----+---+
| base         | 1 |
| current_logfiles | 2 |
| global       | 3 |
| log          | 4 |
| pg_commit_ts | 5 |
+-----+---+
```

Результаты нескольких табличных функций можно объединить, как если бы они были соединены по позиции строки. Для этого служит конструкция **ROWS FROM**. Эта конструкция возвращает *отношение*, поэтому ее можно использовать во фразе **FROM**, как любое другое отношение. Количество строк равно размеру самого большого результата перечисленных функций. Столбцы соответствуют функциям во фразе **ROWS FROM**. Если какая-то функция возвращает меньше строк, чем другие, то отсутствующие значения будут равны **<NULL>**

```
SELECT idx, number FROM
  ROWS FROM (
    generate_series(
      '2020-07-06'::timestamp,
      '2020-10-05'::timestamp,
      '14 days'::interval
    ),
    generate_series(100,105)
  ) AS t(idx, number);
```

Выведет

idx	number
2020-07-06 00:00:00	100
2020-07-20 00:00:00	101
2020-08-03 00:00:00	102
2020-08-17 00:00:00	103
2020-08-31 00:00:00	104
2020-09-14 00:00:00	105
2020-09-28 00:00:00	<NULL>

## 26.5. Функции для работы с массивами

Пример использования функции **unnest**, которая преобразует заданный *массив* в набор *строк*, каждая запись которого соответствует элементу массива

```
SELECT unnest('{2,3,4}'::int[]) AS idx, 5 AS number;
```

Выведет

idx	number
2	5
3	5
4	5

Работа с несколькими массивами

```
SELECT * FROM unnest('{2,3,4}'::int[], '{10,20,30,40}'::int[]);
```

## 26.6. Операторы и функции даты/времени

Вычислить возраст, например, пользователя приложения по дате его рождения удобно с помощью функции **age**

```
SELECT age('1986-08-18'::timestamp); -- 33 years 10 mons 16 days
```

В этом же запросе можно извлечь, например, только полное число лет

```
SELECT extract( 'year' from age('1986-08-18'::timestamp)); -- 33
```

Перекрытие временных диапазонов можно определить с помощью SQL-оператора OVERLAPS.

Пример

```
SELECT  
( '2001-02-16'::date, '2001-12-21'::date)  
OVERLAPS  
( '2001-10-30'::date, '2002-10-30'::date); --t
```

«Усечь» дату до заданной точности можно так

```
SELECT date_trunc('year', '2001-02-16 20:38:40'::timestamp); -- 2001-01-01 00:00:00
```

## 26.7. Выполнение динамически формируемых команд

Часто требуется динамически формировать команды внутри функции на PL/pgSQL, то есть такие команды, в которых при каждом выполнении могут использоваться разные таблицы или типы данных. Обычно PL/pgSQL кеширует планы выполнения, но в случае с динамическими командами это не будет работать.

Для исполнения динамических команд предусмотрен оператор EXECUTE

```
EXECUTE command-string [ INTO [STRICT] target ] [ USING expression [, ...] ];
```

где `command-string` – это выражение, формирующее строку (типа `text`) с текстом команды, которую нужно выполнить. Необязательная цель – это переменная-запись, переменная-кортеж или разделенный запятыми список простых переменных и полей записи/кортежа, куда будут помещены результаты команды. Необязательные выражения в `USING` формируют значения, которые будут вставлены в команду.

В сформированном тексте команды замена имен переменных PL/pgSQL на их значения проводиться не будет. Все необходимые значения переменных должны быть вставлены в командную строку при ее построении, либо нужно использовать параметры, как описано ниже.

Также, *нет никакого плана кеширования* для команд, выполняемых с помощью `EXECUTE`. Вместо этого план создается каждый раз при выполнении. Таким образом, строка команды может динамически создаваться внутри функции для выполнения действий с различными таблицами и столбцами.

Предложение `INTO` указывает, куда должны быть помещены результаты SQL-команды, возвращающей строки. Если используется переменная строкового типа или список переменных, то они должны в точности соответствовать структуре результата запроса (когда используется переменная типа `record`, она автоматически приводится к строковому типу результата запроса). Если возвращается несколько строк, то только первая будет присвоена переменной(ым) в `INTO`. Если не возвращается ни одной строки, то присваивается `NULL`. Без предложения `INTO` результаты запроса отбрасываются.

С указанием `STRICT` запрос должен вернуть ровно одну строку, иначе выдается сообщение об ошибке.



В тексте команды можно использовать значения параметров. Ссылки на эти параметры обозначаются как \$1, \$2 и т.д. Эти символы указывают на значения, находящиеся в предложении USING. Такой метод зачастую предпочтительнее, чем вставка значений в команду в виде текста: он позволяет исключить во время исполнения дополнительные расходы на преобразования значений в тексте и обратно, и не открывает возможности для SQL-инъекций, не требуя применять экранирование или кавычки для спецсимволов.

Пример

```
...
EXECUTE 'SELECT count(*) FROM mytable WHERE inserted_by = $1 AND inserted <= $2'
  INTO с -- число строк связывается с переменной 'с'
  USING checked_user, checked_date;
...
```

Обратите внимание, что символы параметров можно использовать *только* вместо значений данных. Если же требуется *динамически* формировать имена таблиц или столбцов, их необходимо вставлять в виде текста. Например, если в предыдущем запросе необходимо динамически задавать имя таблицы, можно сделать следующее

```
...
EXECUTE 'SELECT count(*) FROM '
  || quote_ident(tabname)
  || ' WHERE inserted_by = $1 AND inserted <= $2'
  INTO с
  USING checked_user, checked_date;
...
```

В качестве более аккуратного решения, вместо имени таблиц или столбцов можно использовать указание формата %I с функцией `format()` (текст, разделенный символами новой строки, соединяется вместе)

```
...
-- самый аккуратный вариант
-- символы $1 и $2 указывают на значения в предложении USING
EXECUTE format('SELECT count(*) FROM %I '
  'WHERE inserted_by = $1 AND inserted <= $2', tabname)
  INTO с
  USING checked_user, checked_date;
...
```

---

#### Замечание

Имена таблиц и столбцов для динамического построения запроса следует вставлять с помощью функции `format()`, а значения атрибутов – с помощью предложения USING (к атрибутам можно обращаться как \$1, \$2 и т.д.)

---

Команда EXECUTE с неизменяемым текстом и параметрами USING, функционально эквивалентна команде, записанной напрямую в PL/pgSQL, в которой переменные PL/pgSQL автоматически заменяются значениями. Важное отличие в том, что EXECUTE при каждом исполнении заново строит план команды с учетом текущих значений параметров, тогда как PL/pgSQL строит *общий план* выполнения и *кеширует* его при повторном использовании. В тех случаях, когда наилучший план выполнения сильно зависит от значений параметров, может быть полезно использовать EXECUTE для *гарантии* того, что не будет выбран общий план.

Указание %I равнозначно вызову `quote_ident`, а %L – вызову `quote_nullable`.

## 26.8. Функции и операторы JSON

Рассмотрим примеры использования операторов для типов json и jsonb

```
-- можно указывать имя ключа в json-объекте или номер этого элемента
-- нумерация начинается с 0
SELECT '[
  { "solver type" : ["direct", "iterative"]},
  { "package name" : "Ansys" }
]':::json->0->'solver type'->>1; -- iterative
```

Использование нотации пути

```
SELECT '[
  { "solver type" : ["direct", "iterative"]},
  { "package name" : "Ansys" }
]':::json #>> '{0, "solver type",1}'; -- iterative
```

Примеры использования дополнительных операторов jsonb

```
-- содержит ли левый json-объект правый json-объект
SELECT '{
  "solver type" : [ "iterative", "direct" ],
  "package name" : "Ansys"
}':::jsonb @> '{ "solver type" : [ "iterative" ] }':::jsonb; -- t
```

```
-- содержится ли левый json-объект в правом
SELECT '{ "package name" : "Ansys" }':::jsonb <@ '{ "package name" : "Ansys", "solver type" : "direct" }':::jsonb;
```

```
-- присутствует ли ключ в формате СТРОКИ в данном json-объекте
SELECT '{ "package name" : "Nastran",
  "solver type" : [ "iterative", "direct" ] }':::jsonb ? 'solver type'; -- t
```

```
-- содержит ли данный json-объект ХОТЯ БЫ один элемент из указанного массива СТРОК
SELECT '{
  "package name" : "Abaqus",
  "solver type" : "direct"
}':::jsonb ?| '{"package name","solver type"}':::text[];
```

```
-- содержит ли данный json-объект ВСЕ элемент из указанного массива СТРОК
SELECT '{
  "package name" : "Abaqus",
  "solver type" : "direct"
}':::jsonb ?& '{"package name","solver type"}':::text[];
```

```
-- удаляет пару ключ/значение или элемент-СТРОКУ из левого операнда
SELECT '{
  "package name" : "Abaqus",
  "solver type" : "direct"
}':::jsonb - 'solver type';
```

```
-- удаляет поле или элемент с заданным путем
SELECT '{
  "package name" : "Abaqus",
  "solver type" :
    {
      "direct" : "Java",
      "iterative" : "IronPython"
    }
}':::jsonb #- '{"solver type","iterative"}':::text[];
```

Чтобы убедиться в том, что найден правильный элемент json-объект, следует сначала воспользоваться оператором #>, а уже потом оператором #-.

Функции json\_each() и jsonb\_each() разворачивают внешний объект JSON в набор пар ключ/значение

```
SELECT * FROM jsonb_each(
  '{
    "package name" : "Abaqus",
    "solver type" : { "direct" : "Java", "iterative" : "IronPython" }
  }'::jsonb #- '{"solver type", "direct"}'::text[]
);
```

ВЫВЕДЕТ

key	value
solver type	{"iterative": "IronPython"}
package name	"Abaqus"

Для того чтобы развернуть внешний объект JSON в набор пар ключ/значение в текстовом формате, следует воспользоваться функциями json\_each\_text() и jsonb\_each\_text().

Ключи JSON-объекта можно вернуть так

```
-- выведет ключи JSON-объекта верхнего уровня
SELECT jsonb_object_keys(
  '{
    "package name" : "Nastran",
    "solver type" : { "direct" : "Java", "iterative" : "IronPython" }
  }'::jsonb #- '{"solver type",direct}'::text[]
);
```

Обновить или создать новый элемент JSON-объект можно так

```
-- заменим 'direct' на 'DIRECT', так как 'create_missing' = false
SELECT jsonb_set(
  '{
    "package name" : "Ansys",
    "solver type" : [ "direct", "iterative" ]
  }'::jsonb, -- где меняем
  '{"solver type",0}'::text[], -- путь в json-объекте
  '"DIRECT"'::jsonb, -- на что меняем
  false -- обновляем значение
  -- true -- добавляем новое значение
);
```

```
-- добавит новое значение 'NEW TYPE' в 'solver type', так как в этом ключе нет элемента с номером
  позиции 2, а 'create_missing' = true
SELECT jsonb_set(
  '{
    "package name" : "Ansys",
    "solver type" : [ "direct", "iterative" ]
  }'::jsonb, -- где меняем
  '{"solver type",2}'::text[], -- путь в json-объекте
  '"NEW TYPE"'::jsonb, -- на что меняем
  true -- добавляем новое значение
);
```

Для того чтобы упростить восприятие сложных JSON-объектов служит функция json\_pretty()

```
SELECT * FROM jsonb_pretty(
  '{ "pretty name" : "Ansys",
    "solver type" : [ "direct", "interactive" ]
  }'::jsonb
) AS "json object";
```

ВЫВЕДЕТ

```
+-----+
|          json object          |
+-----+
| {                               +|
|   "pretty name": "Ansys",      +|
|   "solver type": [             +|
|       "direct",                +|
|       "interactive"            +|
|   ]                             +|
| }                               |
+-----+
```

## 27. Наиболее полезные команды PostgreSQL

### 27.1. Команда VACUUM

Команда **VACUUM** предназначена для сборки мусора и, возможно, для анализа базы данных. **VACUUM** высвобождает пространство, занятое «мертвыми» кортежами. При обычных операциях кортежи, удаленные или устаревшие в результате обновления, физически не удаляются из таблицы. Они сохраняются в ней, и ждут выполнения команды **VACUUM**. Таким образом, периодически необходимо выполнять **VACUUM**, особенно для часто изменяемых таблиц.

Без параметра команда **VACUUM** обрабатывает *все таблицы* текущей базы данных, которые может очистить текущий пользователь. Если в параметре передается имя таблицы, то **VACUUM** обрабатывает только эту таблицу.

Конструкция **VACUUM ANALYZE** выполняет очистку, а затем анализ всех указанных таблиц. Параметр **ANALYZE** обновляет статистическую информацию по таблицам, которую использует планировщик при выборе наиболее эффективного способа выполнения запроса. Это удобная комбинация для регулярного обслуживания БД.

Пример

```
VACUUM (VERBOSE, ANALYZE) onek;
```

## Список литературы

1. Джуба С., Волков А. Изучаем PostgreSQL 10. – М.: ДМК Пресс, 2019. – 400 с.
2. Чакон С., Штрауб Б. Git для профессионального программиста. – СПб.: Питер, 2020. – 496 с.
3. Соболев М. Linux. Администрирование и системное программирование. 2-е изд. – СПб.: Питер, 2011. – 880 с.